Оглавление

1 Введение **1**

2 Поиск и выбор набора данных для построения моделей машинного обучения. На основе выбранного набора данных студент должен построить модели машинного обучения для решения задачи регрессии. **2**

2.1 Импорт библиотек 3

2.2 Загрузка данных 3

3 Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных. **3**

3.1 Построение графиков для понимания структуры данных 5

4 Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков. Масштабирование данных. Формирование вспомогательных признаков, улучшающих качество моделей. **16**

5 Проведение корреляционного анализа данных. Формирование промежуточных выводов о возможности построения моделей машинного обучения **25**

6 Выбор метрик для последующей оценки качества моделей. **27**

6.1 Сохранение и визуализация метрик 27

7 Выбор наиболее подходящих моделей для решения задачи классификации или регрессии. **28**

8 Формирование обучающей и тестовой выборок на основе исходного набора данных **28**

9 Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки. **29**

10 Подбор гиперпараметров для выбранных моделей. Рекомендуется использовать методы кросс-валидации. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы. **30**

11 Повторение пункта 8 для найденных оптимальных значений гиперпараметров. Сравнение качества полученных моделей с качеством baseline-моделей. **35**

12 Формирование выводов о качестве построенных моделей на основе выбранных метрик. Результаты сравнения качества рекомендуется отобразить в виде графиков и сделать выводы в форме текстового описания. Рекомендуется построение графиков обучения и валидации, влияния значений гиперпарметров на качество моделей и т.д. **36**

13 AutoML **38**

14 Код для макета WEB-версии **40**

15 Заключение **46**

16 Список использованных источников **46**

1 Введение

Курсовой проект – самостоятельная часть учебной дисциплины «Технологии машинного обучения» – учебная и практическая исследовательская студенческая работа, направленная на решение комплексной задачи машинного обучения. Результатом курсового проекта является отчет, содержащий описания моделей, тексты программ и результаты экспериментов.

Курсовой проект опирается на знания, умения и владения, полученные студентом в рамках лекций и лабораторных работ по дисциплине.

В рамках курсового проекта я должен провести решение задачи машинного обучения на основе материалов дисциплины.

2 Поиск и выбор набора данных для построения моделей машинного обучения. На основе выбранного набора данных студент должен построить модели машинного обучения для решения задачи регрессии.

В качестве набора данных мы будем использовать набор данных по продажам домов в США за Май 2014 - Май 2015 - https://www.kaggle.com/harlfoxem/housesalesprediction?select=kc_house_data.csv

Датасет состоит из 1 файла: kc_house_data.csv

Файл описывает следующие колонки:

id - уникальный id продажи дома

date - дата продажи дома

price - цена продажи дома

bedrooms - кол-во спальных комнат

bathrooms - кол-во ванных комнат (где .5 считается за комнату с туалетом без душа)

sqft_living - жилая площадь(кв. футах)

sqft_lot - площать земли

floors - кол-во этажей

waterfront - рядом с водой (1 или 0)

view - хороший вид (от 0 или 4)

condition - условия апартаметов (от 1 до 5)

grade - оценка (от 1 до 13)

sqft_above - площадь пространства, выше земли

sqft_basement - площадь пространства, ниже земли(подвал)

yr_built - год постройки

yr_renovated - год реновации

zipcode - почтовый код

lat - долгота (координаты)

long - широта (координаты)

sqft_living15 - площадь внутренней жилой площади для ближайших 15 соседей

sqft_lot15 - площадь земли для ближайших 15 соседей

В рассматриваемом примере будем решать задачу регрессии - целевой признак ‘price’ - цена

2.1 Импорт библиотек

[1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from typing import Dict, Tuple
from IPython.display import Image

from sklearn.preprocessing import MinMaxScaler
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score,
 ↪classification_report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import plot_confusion_matrix
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import mean_absolute_error, mean_squared_error,
 ↪mean_squared_log_error, median_absolute_error, r2_score
from sklearn.metrics import roc_curve, roc_auc_score
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor
from sklearn.ensemble import GradientBoostingClassifier, GradientBoostingRegressor
```

2.2 Загрузка данных

Загрузим файлы датасета в помощью библиотеки Pandas.

Файл представляет собой данные в формате CSV. Разделитель - ‘,’

[2]:
```
data = pd.read_csv("data/kc_house_data.csv", sep=',')
```

3 Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных.

[3]:
```
data.head()
```

[3]:
```
           id             date     price  bedrooms  bathrooms  sqft_living  \
0  7129300520  20141013T000000  221900.0         3       1.00         1180
1  6414100192  20141209T000000  538000.0         3       2.25         2570
2  5631500400  20150225T000000  180000.0         2       1.00          770
3  2487200875  20141209T000000  604000.0         4       3.00         1960
4  1954400510  20150218T000000  510000.0         3       2.00         1680

   sqft_lot  floors  waterfront  view  …  grade  sqft_above  sqft_basement  \
0      5650     1.0           0     0  …      7        1180              0
1      7242     2.0           0     0  …      7        2170            400
2     10000     1.0           0     0  …      6         770              0
3      5000     1.0           0     0  …      7        1050            910
4      8080     1.0           0     0  …      8        1680              0

   yr_built  yr_renovated  zipcode      lat     long  sqft_living15  \
0      1955             0    98178  47.5112 -122.257           1340
1      1951          1991    98125  47.7210 -122.319           1690
2      1933             0    98028  47.7379 -122.233           2720
3      1965             0    98136  47.5208 -122.393           1360
4      1987             0    98074  47.6168 -122.045           1800

   sqft_lot15
0        5650
1        7639
2        8062
3        5000
4        7503

[5 rows x 21 columns]
```

[4]:
```
data.shape
```

[4]:
```
(21613, 21)
```

[5]:
```
data.dtypes
```

[5]:
```
id                int64
date             object
price           float64
bedrooms          int64
```

```
bathrooms        float64
sqft_living        int64
sqft_lot           int64
floors           float64
waterfront         int64
view               int64
condition          int64
grade              int64
sqft_above         int64
sqft_basement      int64
yr_built           int64
yr_renovated       int64
zipcode            int64
lat              float64
long             float64
sqft_living15      int64
sqft_lot15         int64
dtype: object
```

[6]:
```
data.isnull().sum()
```

[6]:
```
id               0
date             0
price            0
bedrooms         0
bathrooms        0
sqft_living      0
sqft_lot         0
floors           0
waterfront       0
view             0
condition        0
grade            0
sqft_above       0
sqft_basement    0
yr_built         0
yr_renovated     0
zipcode          0
lat              0
long             0
sqft_living15    0
sqft_lot15       0
dtype: int64
```

Вывод: исходный набор данных данных не содержит пропусков

3.1 Построение графиков для понимания структуры данных

Сразу удалим ненужные столбцы - уникальный id и уникальную дату.

[7]:
```
sns.pairplot(data)
```

[7]:
```
<seaborn.axisgrid.PairGrid at 0x7efce06511f0>
```

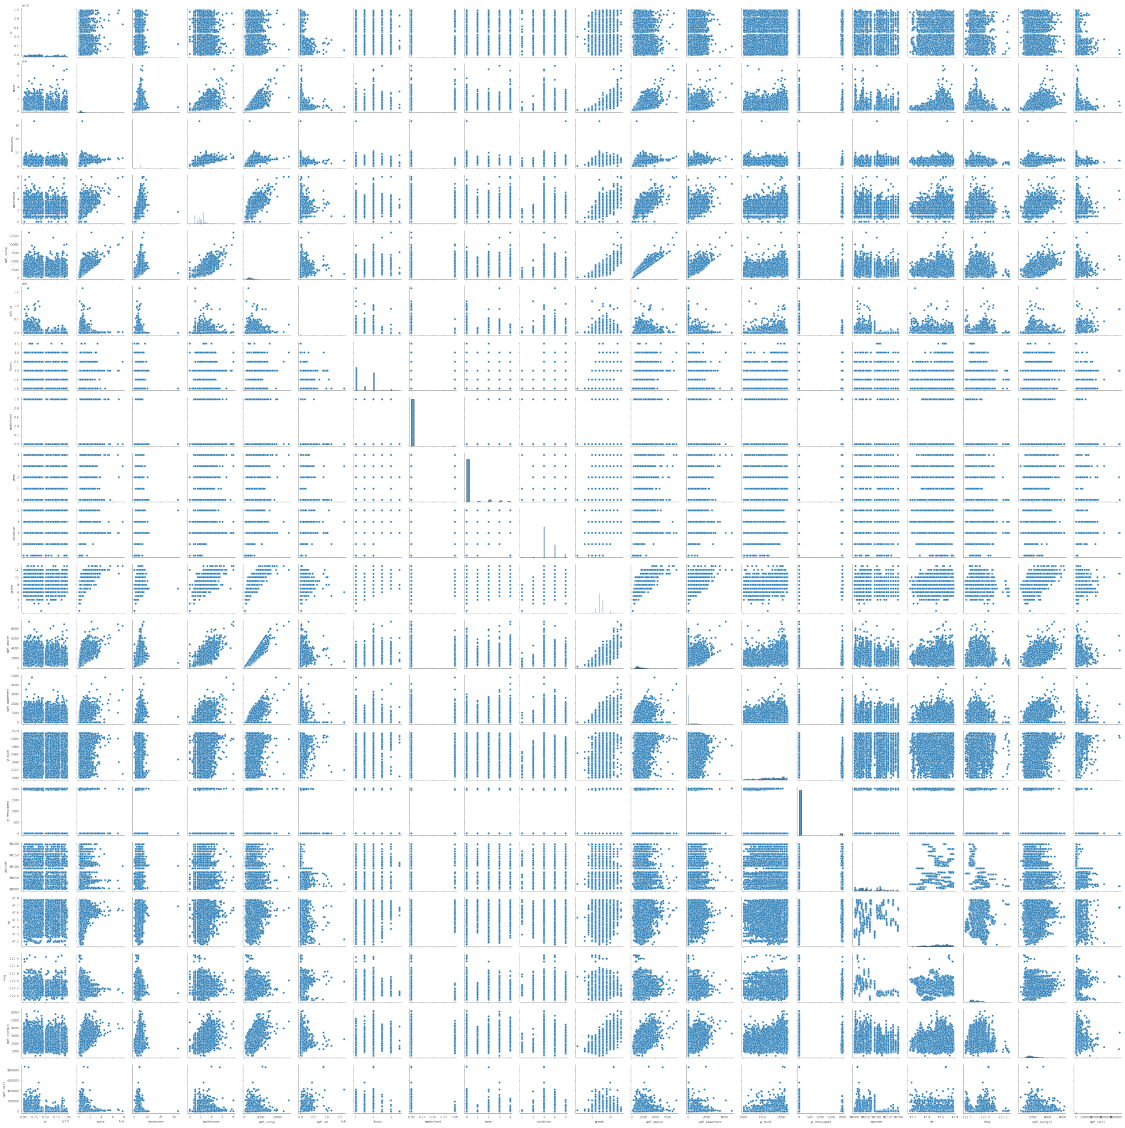

[8]:
```
data.columns
```

[8]:
```
Index(['id', 'date', 'price', 'bedrooms', 'bathrooms', 'sqft_living',
       'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade',
       'sqft_above', 'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode',
       'lat', 'long', 'sqft_living15', 'sqft_lot15'],
```

```
      dtype='object')
```

[9]:
```
# Скрипичные диаграммы для числовых колонок
for col in ['price', 'bedrooms', 'bathrooms', 'sqft_living',
       'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade',
       'sqft_above', 'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode',
       'lat', 'long', 'sqft_living15', 'sqft_lot15']:
    sns.violinplot(x=data[col])
    plt.show()
```

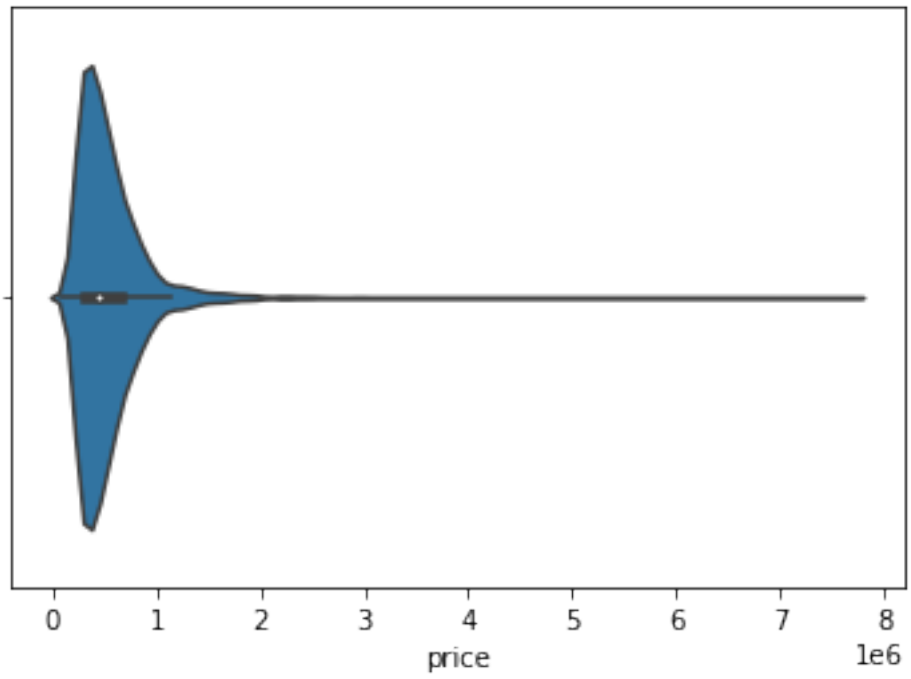

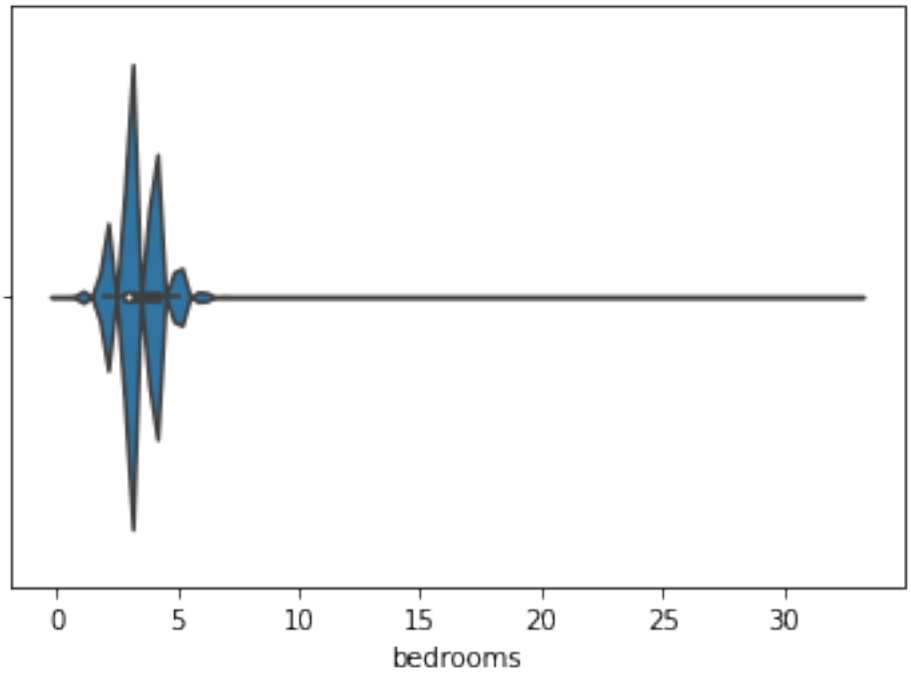
0
5
10
15
20
25
30
bedrooms

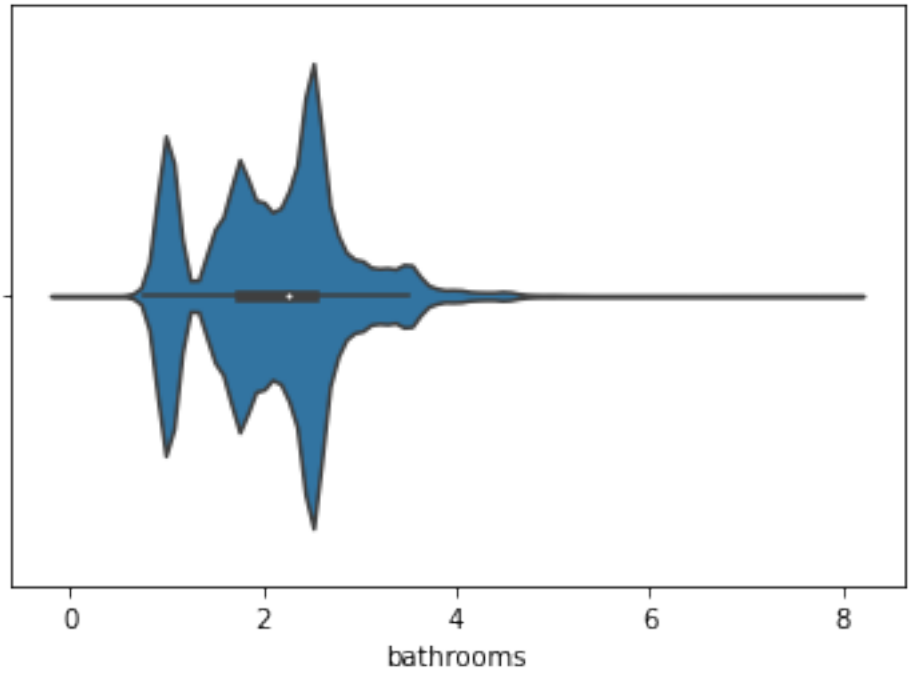
0
2
4
6
8
bathrooms

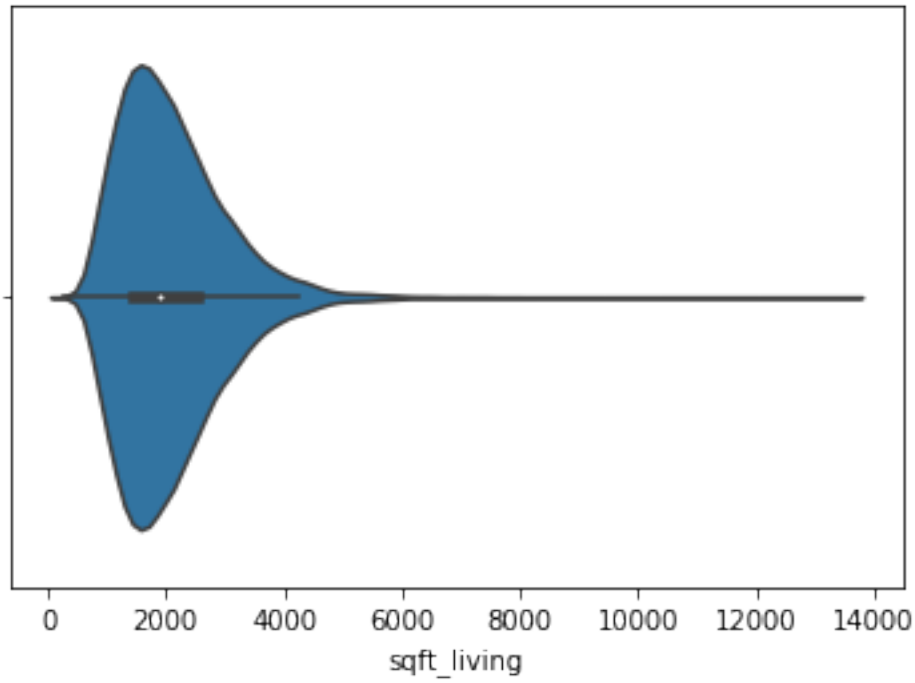
0
2000
4000
6000
8000
10000
12000
14000
sqft_living

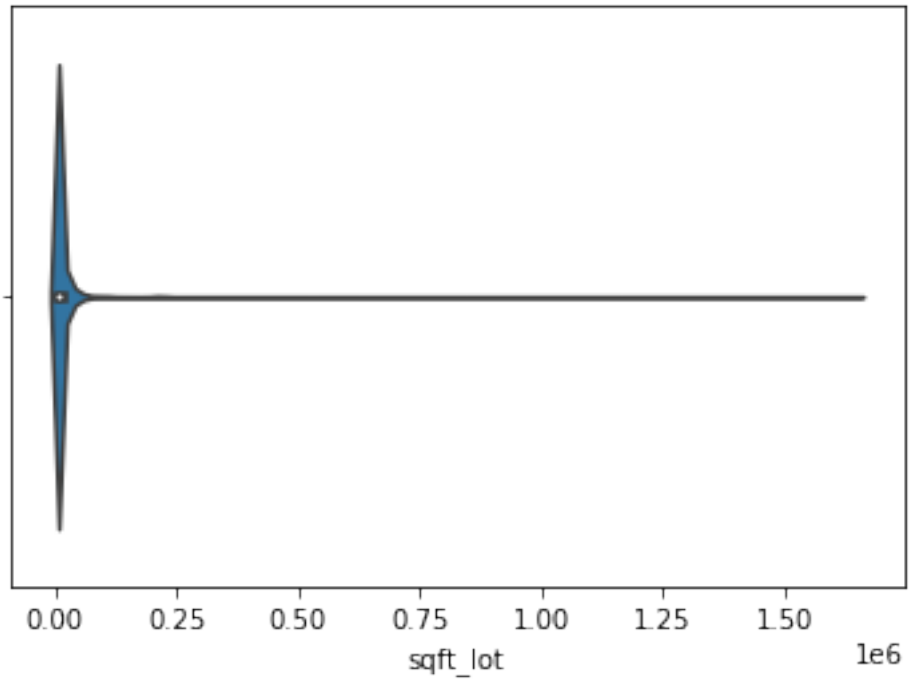
0.00
0.25
0.50
0.75
1.00
1.25
1.50
1e6
sqft_lot

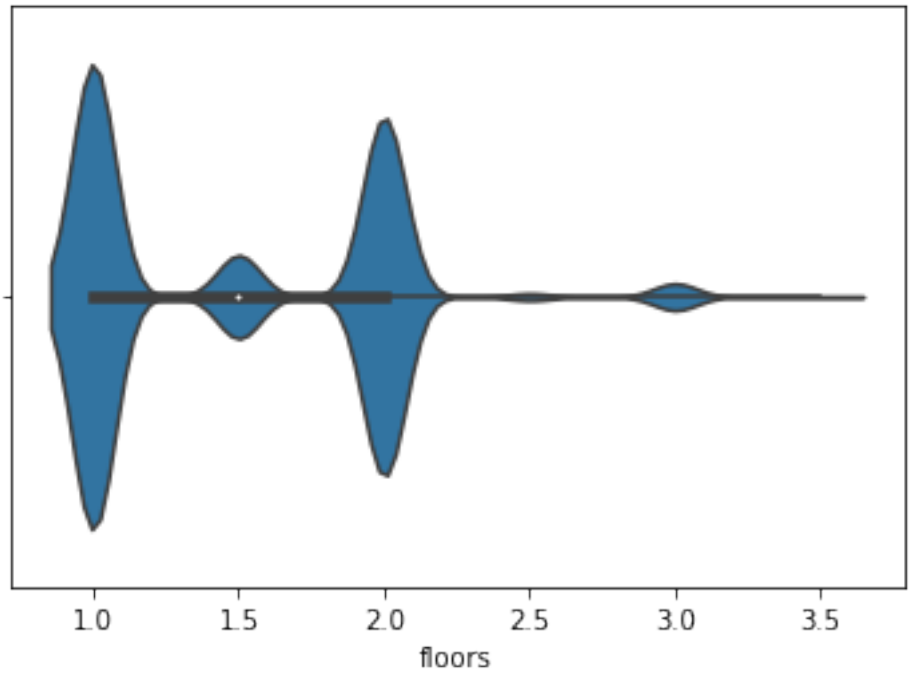
1.0
1.5
2.0
2.5
3.0
3.5
floors

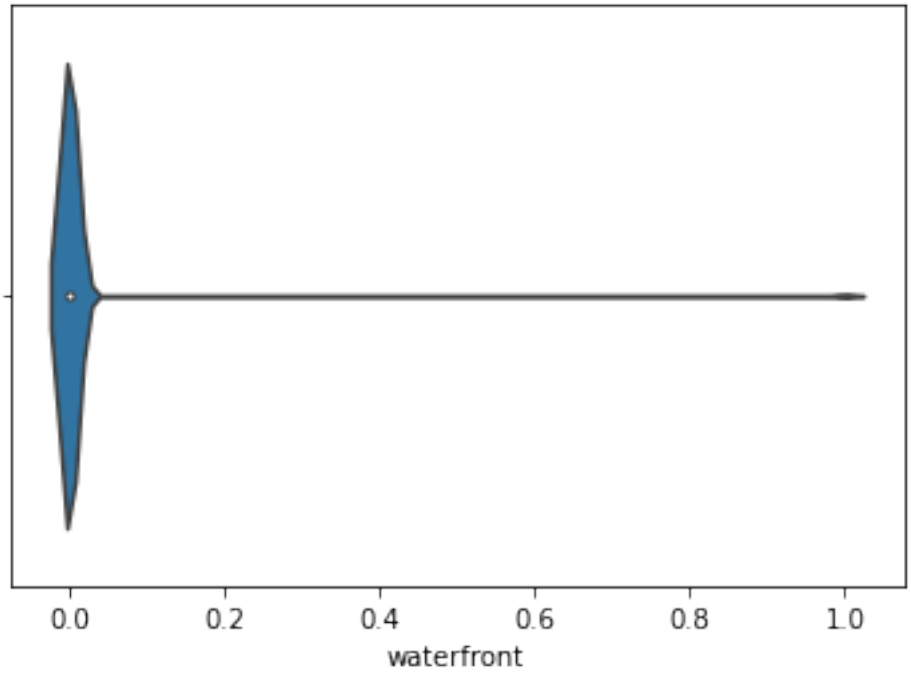
0.0
0.2
0.4
0.6
0.8
1.0
waterfront

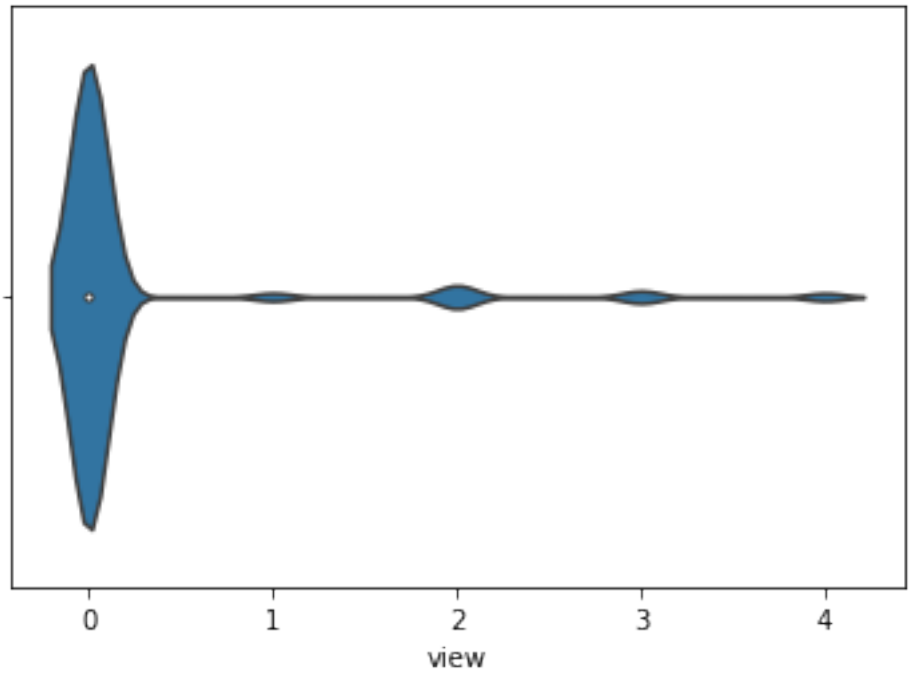
0
1
2
3
4
view

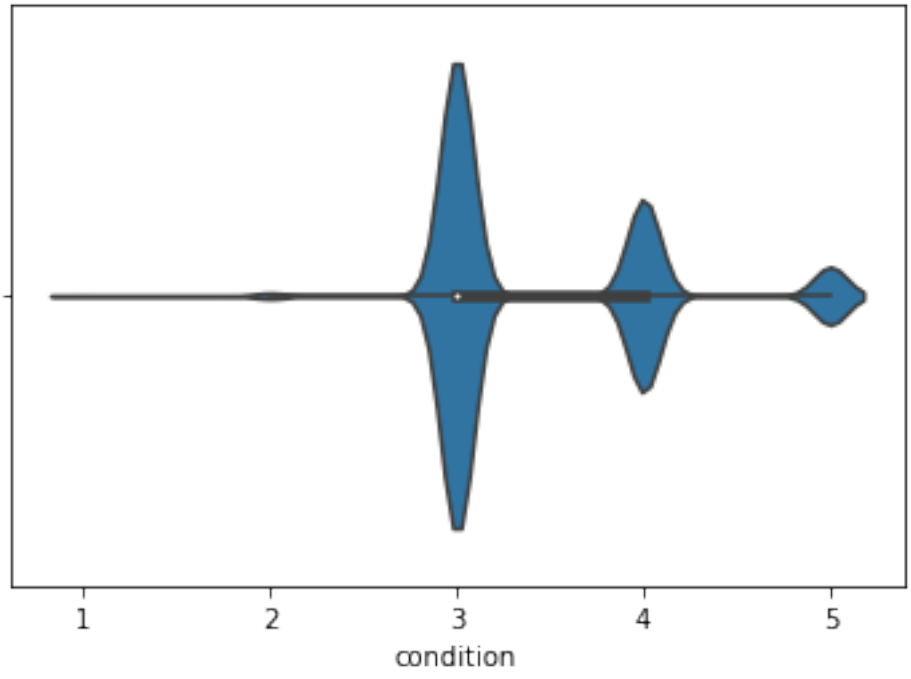
1
2
3
4
5
condition

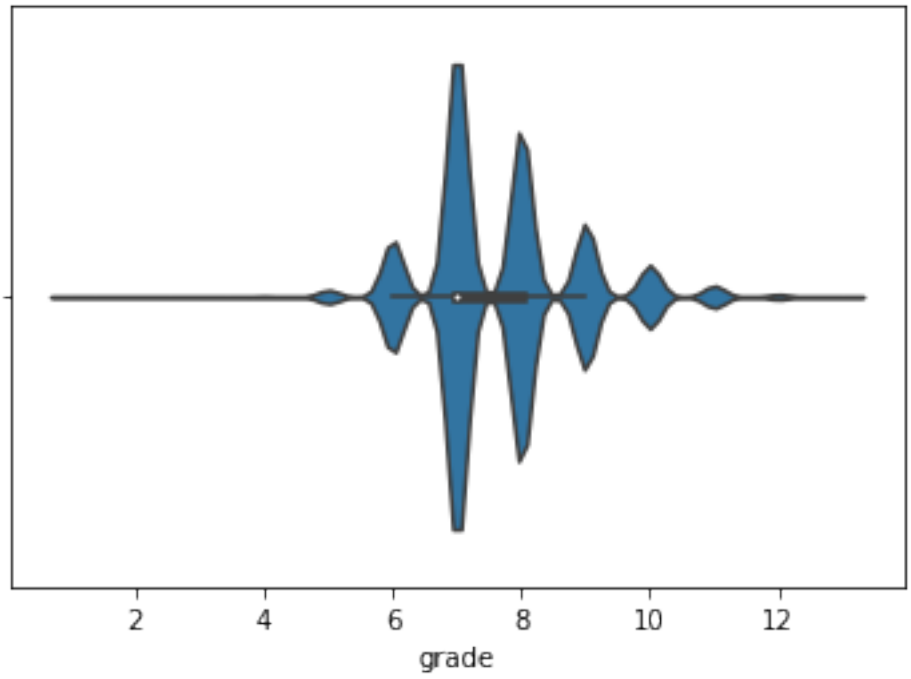
2
4
6
8
10
12
grade

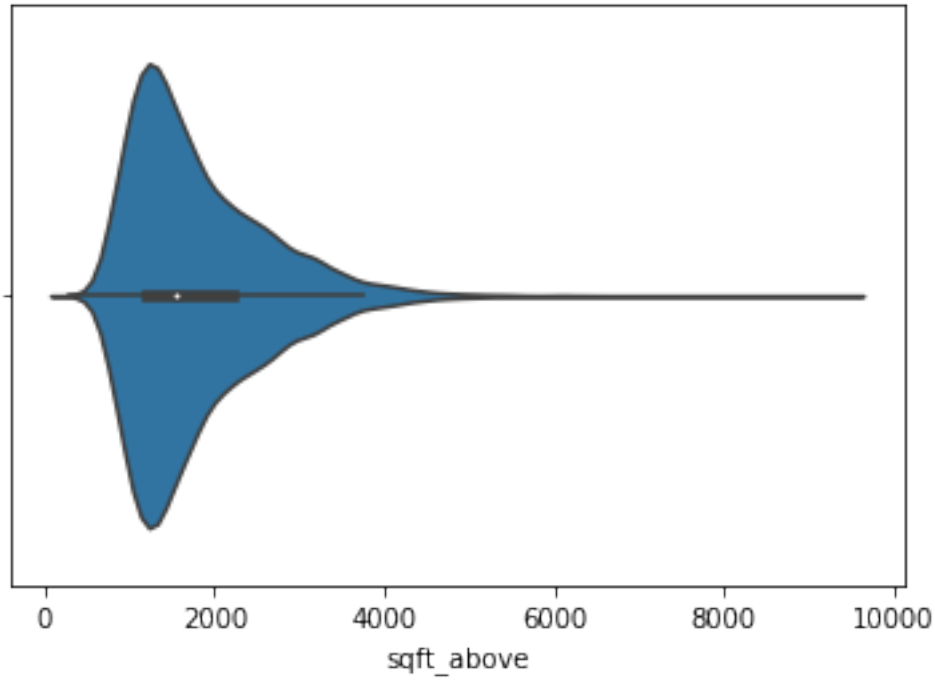
0
2000
4000
6000
8000
10000
sqft_above

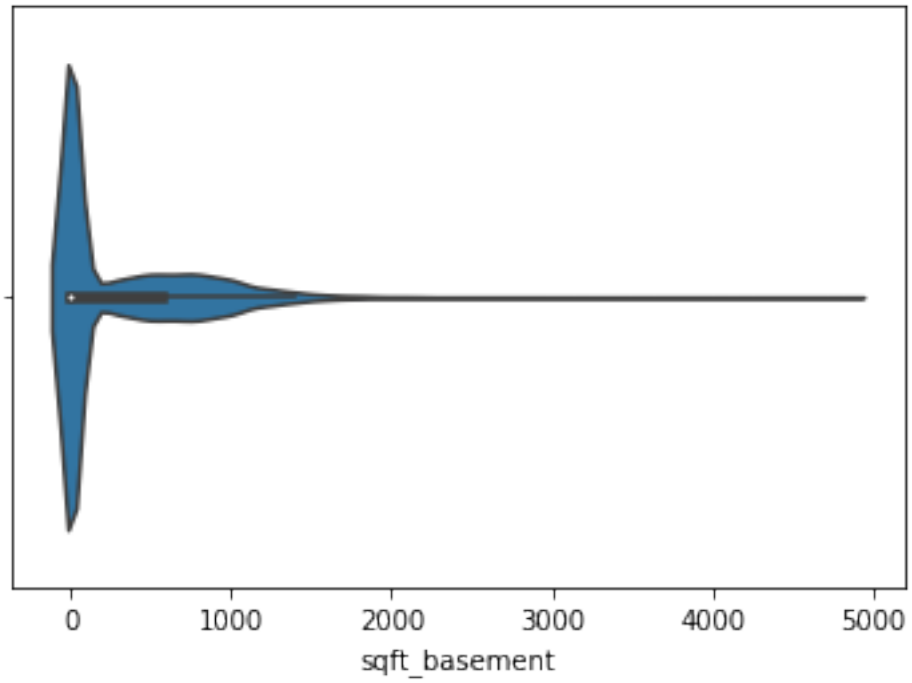
0
1000
2000
3000
4000
5000
sqft_basement

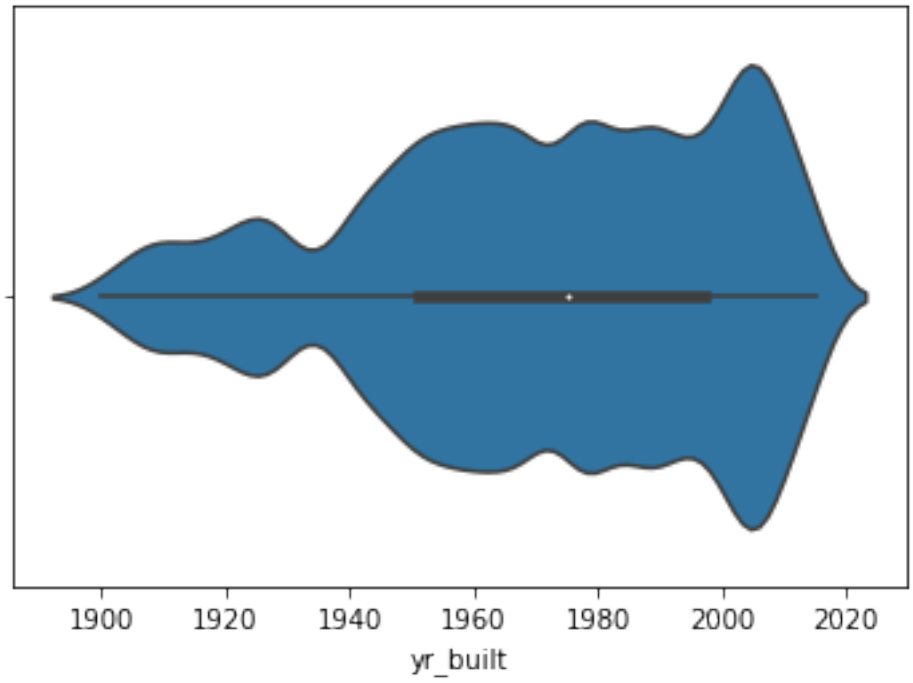
1900
1920
1940
1960
1980
2000
2020
yr_built

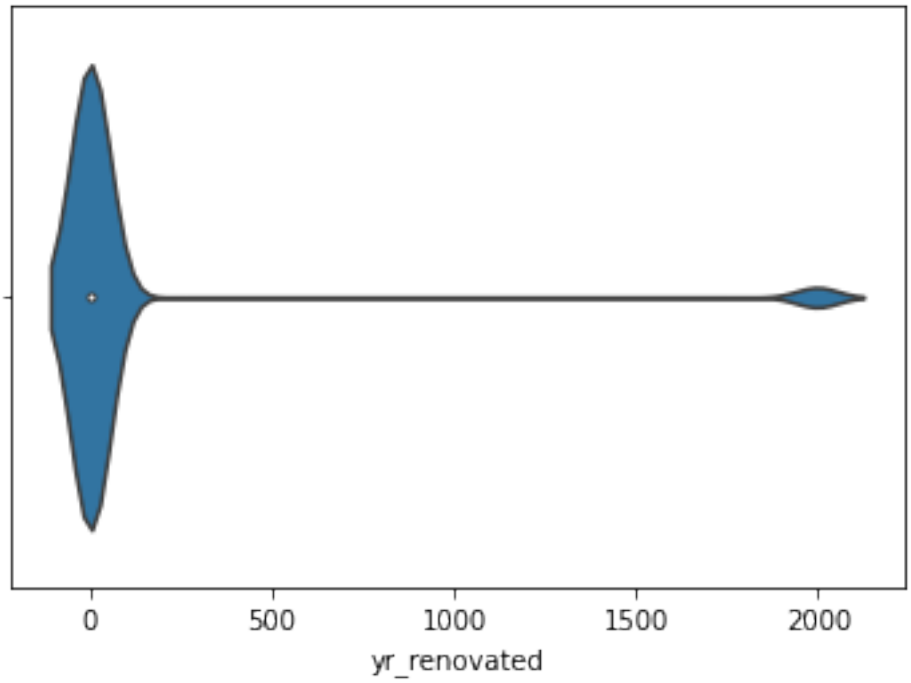
0
500
1000
1500
2000
yr_renovated

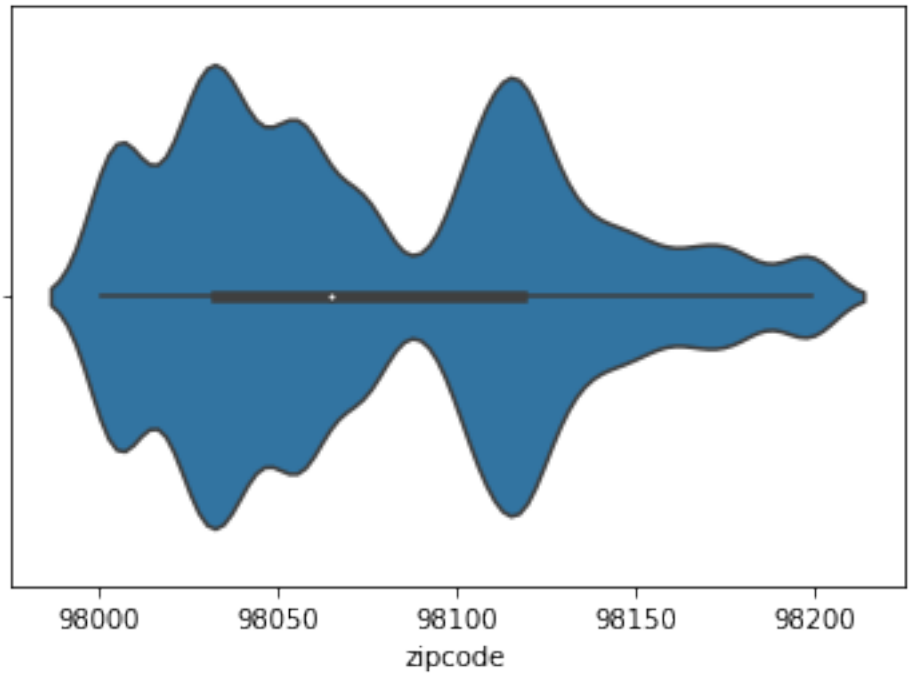
98000
98050
98100
98150
98200
zipcode

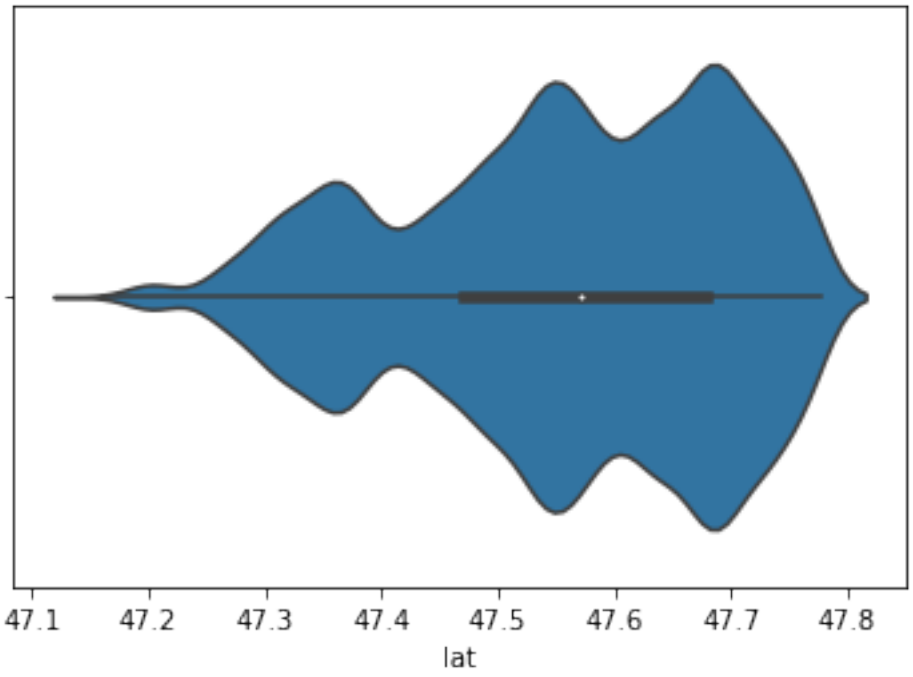
47.1
47.2
47.3
47.4
47.5
47.6
47.7
47.8
lat

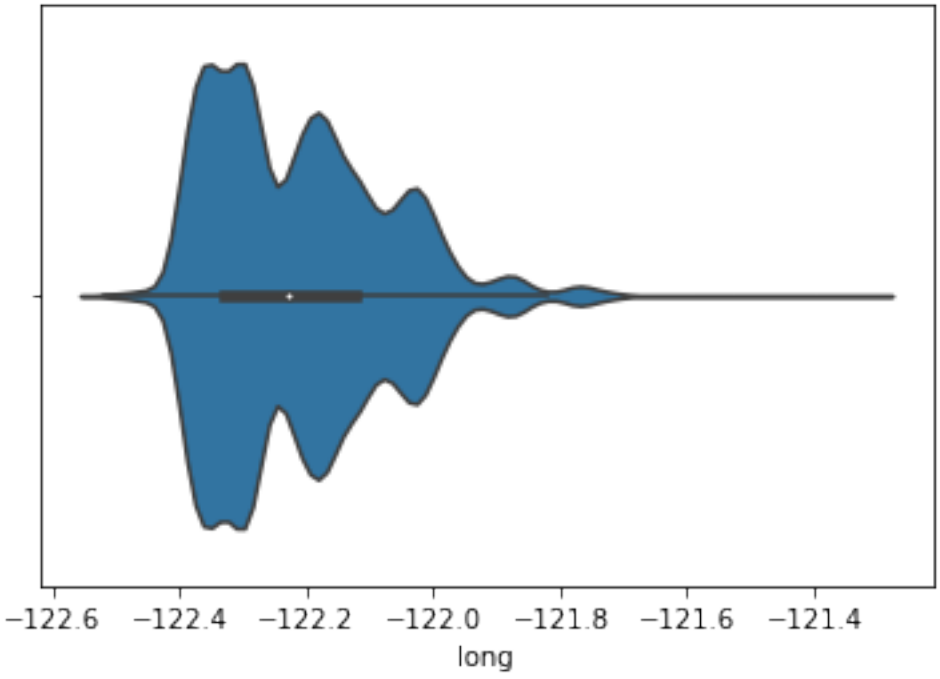
−122.6
−122.4
−122.2
−122.0
−121.8
−121.6
−121.4
long

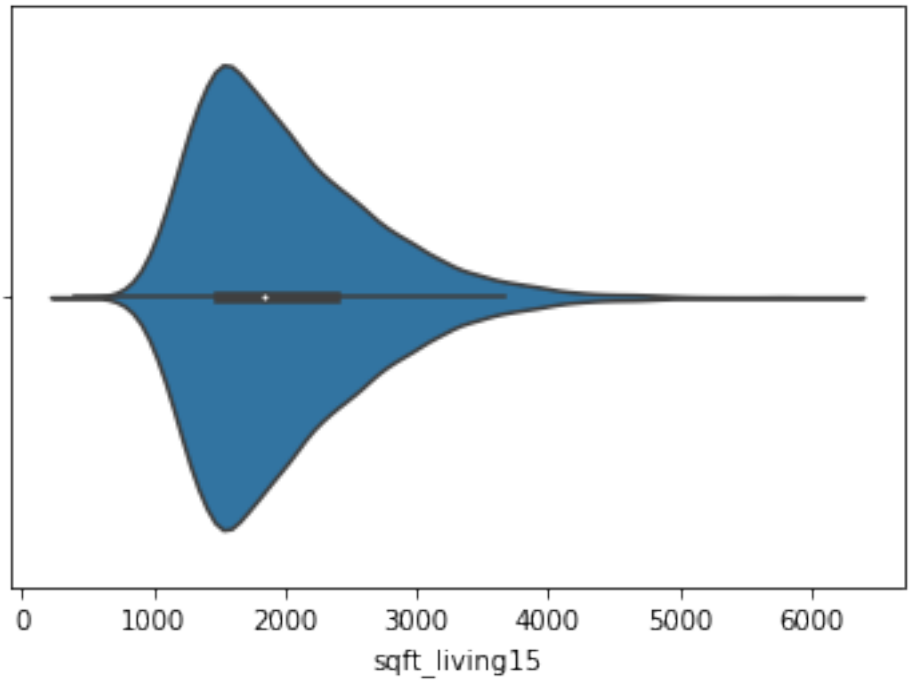
0
1000
2000
3000
4000
5000
6000
sqft_living15

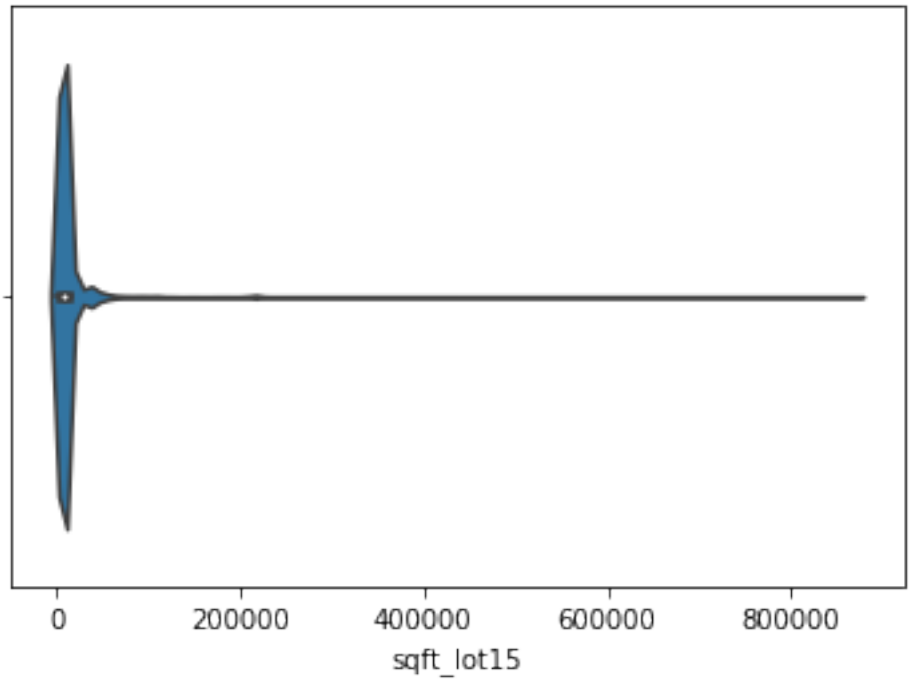
0
200000
400000
600000
800000
sqft_lot15

4 Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков. Масштабирование данных. Формирование вспомогательных признаков, улучшающих качество моделей.

[10]:
```
data.dtypes
```

[10]:
```
id                int64
date             object
price           float64
bedrooms          int64
bathrooms       float64
sqft_living       int64
sqft_lot          int64
floors          float64
waterfront        int64
view              int64
condition         int64
grade             int64
sqft_above        int64
sqft_basement     int64
yr_built          int64
yr_renovated      int64
zipcode           int64
lat             float64
long            float64
sqft_living15     int64
sqft_lot15        int64
dtype: object
```

Пока для построения модели будем использовать все признаки, кроме ‘date’, т.к. не рассматриваем нашу модель как временную, и ‘id’, т.к. он содержит уникальынй id покупки, который мы не рассматриваем в модели вообще.

[11]:
```
data.drop(['id', 'date'], axis=1, inplace=True)
```

Категориальные признаки отсутствуют, их кодирования не требуется(date не рассматриваем).

Вспомогательные признаки для улучшения качества моделей в данном примере мы строить не будем.

Выполним масштабирование данных(построим корреляционную карту, чтобы сравнить её с полученной в корреляционном анализе).

[12]:
```
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

[12]:
```
<AxesSubplot:>
```

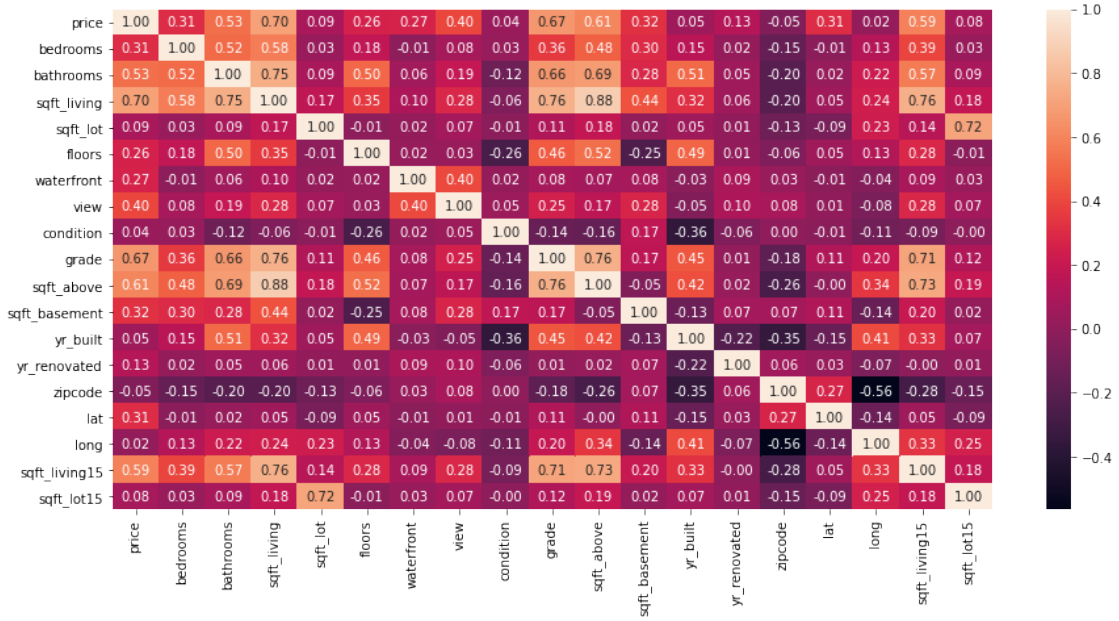

[13]:
```
# Числовые колонки для масштабирования
scale_cols = ['sqft_living', 'sqft_lot', 'sqft_above',
              'sqft_basement', 'lat', 'long',
              'sqft_living15', 'sqft_lot15', 'bedrooms',
              'bathrooms', 'view', 'grade', 'floors', 'yr_renovated', 'yr_built',
 ↪'condition'
             ]
```

[14]:
```
sc = MinMaxScaler()
sc_data = sc.fit_transform(data[scale_cols])
```

[15]:
```
# Добавим масштабированные данные в набор данных
for i in range(len(scale_cols)):
    col = scale_cols[i]
    new_col_name = col + '_scaled'
    data[new_col_name] = sc_data[:,i]
```

[16]:
```
data.head()
```

[16]:

	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	\
0	221900.0	3	1.00	1180	5650	1.0	0	
1	538000.0	3	2.25	2570	7242	2.0	0	
2	180000.0	2	1.00	770	10000	1.0	0	
3	604000.0	4	3.00	1960	5000	1.0	0	
4	510000.0	3	2.00	1680	8080	1.0	0	

	view	condition	grade	…	sqft_living15_scaled	sqft_lot15_scaled	\
0	0	3	7	…	0.161934	0.005742	

```
1     0          3      7  …              0.222165           0.008027
2     0          3      6  …              0.399415           0.008513
3     0          5      7  …              0.165376           0.004996
4     0          3      8  …              0.241094           0.007871

   bedrooms_scaled  bathrooms_scaled  view_scaled  grade_scaled  \
0         0.090909           0.12500          0.0      0.500000
1         0.090909           0.28125          0.0      0.500000
2         0.060606           0.12500          0.0      0.416667
3         0.121212           0.37500          0.0      0.500000
4         0.090909           0.25000          0.0      0.583333

   floors_scaled  yr_renovated_scaled  yr_built_scaled  condition_scaled
0            0.0             0.000000         0.478261               0.5
1            0.4             0.988089         0.443478               0.5
2            0.0             0.000000         0.286957               0.5
3            0.0             0.000000         0.565217               1.0
4            0.0             0.000000         0.756522               0.5

[5 rows x 35 columns]
```

[17]:
```
# Проверим, что масштабирование не повлияло на распределение данных
for col in scale_cols:
    col_scaled = col + '_scaled'

    fig, ax = plt.subplots(1, 2, figsize=(8,3))
    ax[0].hist(data[col], 50)
    ax[1].hist(data[col_scaled], 50)
    ax[0].title.set_text(col)
    ax[1].title.set_text(col_scaled)
    plt.show()
```

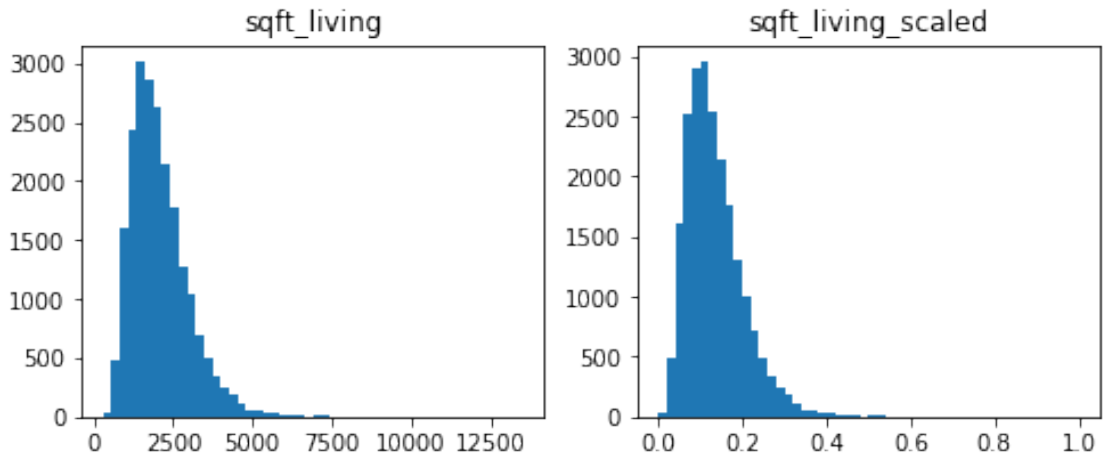

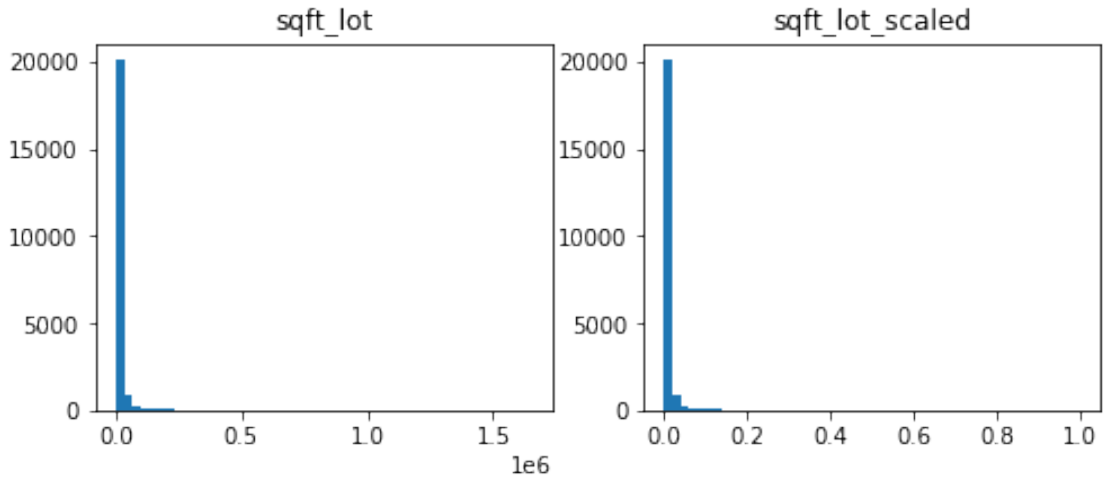
sqft_lot
20000
15000
10000
5000
0
0.0
0.5
1.0
1.5
1e6

sqft_lot_scaled
20000
15000
10000
5000
0
0.0
0.2
0.4
0.6
0.8
1.0

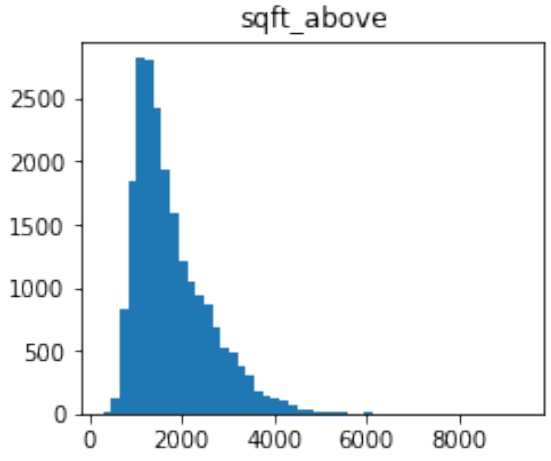
sqft_above
2500
2000
1500
1000
500
0
0
2000
4000
6000
8000

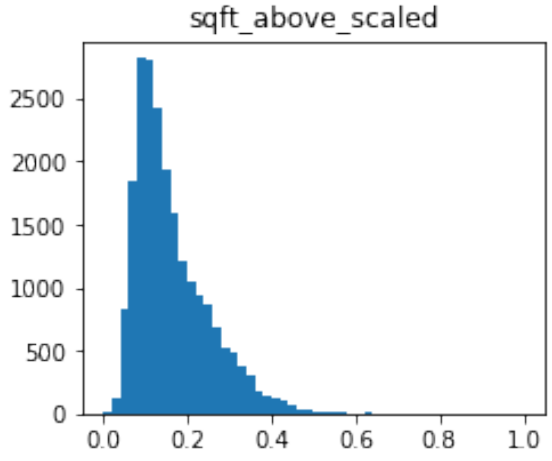
sqft_above_scaled
2500
2000
1500
1000
500
0
0.0
0.2
0.4
0.6
0.8
1.0

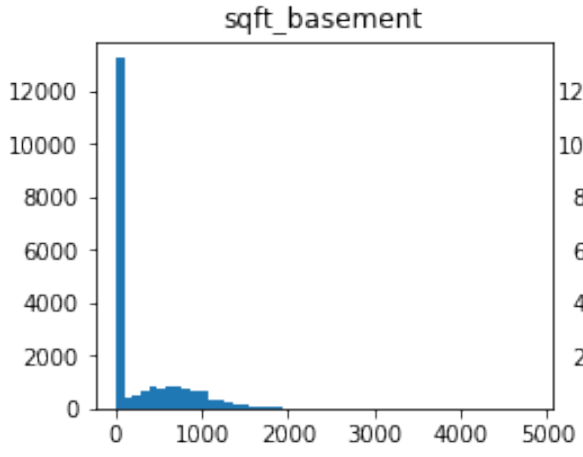
sqft_basement
12000
10000
8000
6000
4000
2000
0
0
1000
2000
3000
4000
5000

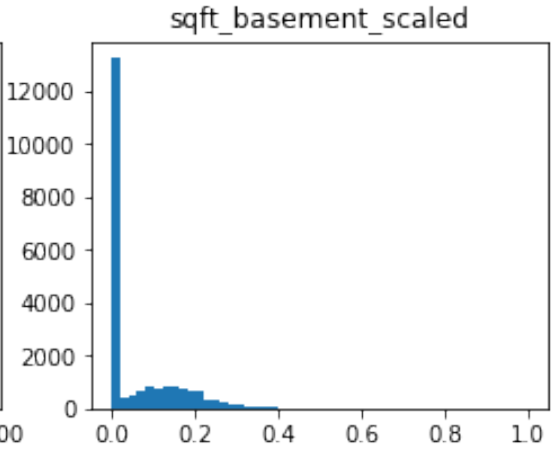
sqft_basement_scaled
12000
10000
8000
6000
4000
2000
0
0.0
0.2
0.4
0.6
0.8
1.0

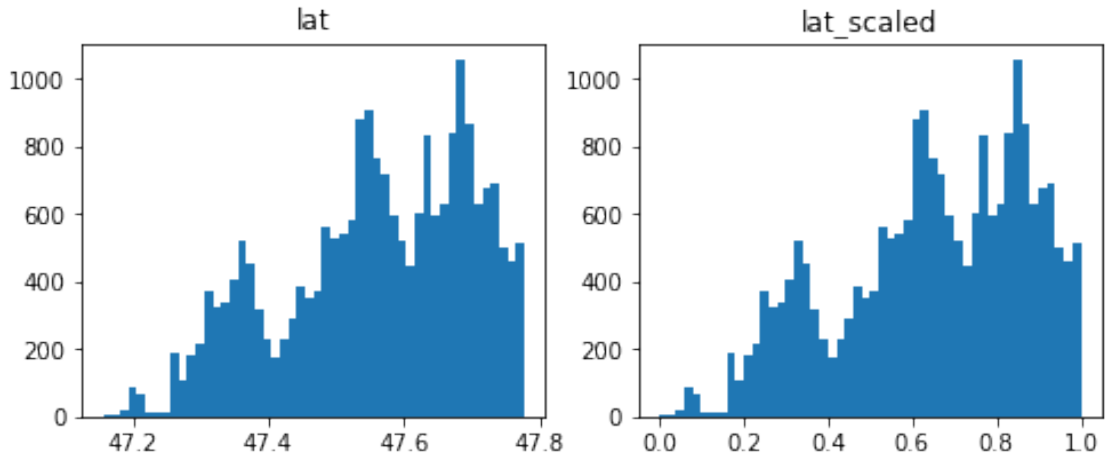
lat
1000
800
600
400
200
0
47.2
47.4
47.6
47.8

lat_scaled
1000
800
600
400
200
0
0.0
0.2
0.4
0.6
0.8
1.0

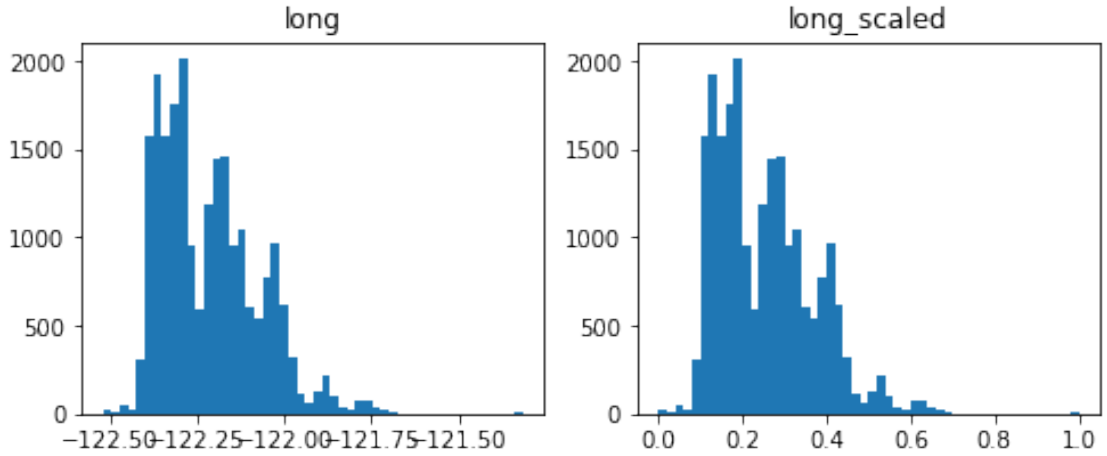
long
2000
1500
1000
500
0
−122.50
−122.25
−122.00
−121.75
−121.50

long_scaled
2000
1500
1000
500
0
0.0
0.2
0.4
0.6
0.8
1.0

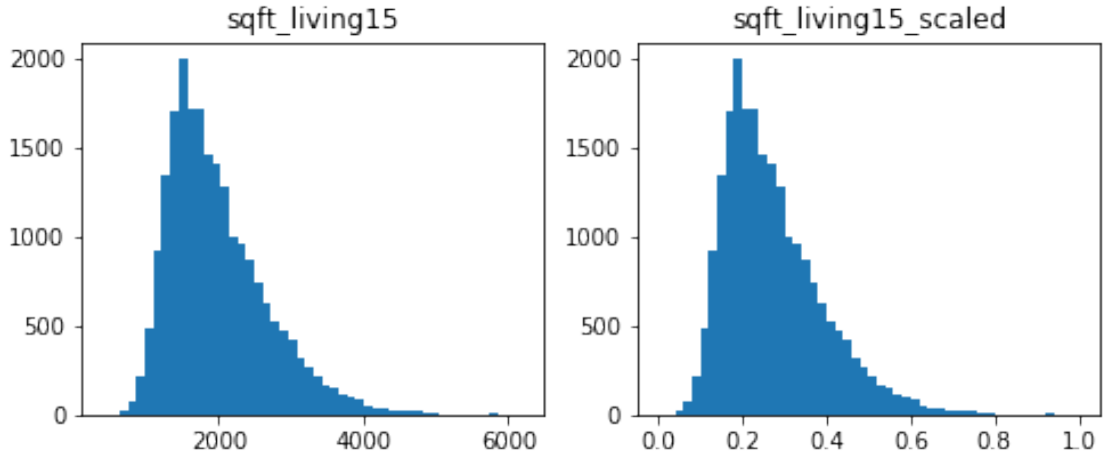
sqft_living15
2000
1500
1000
500
0
2000
4000
6000

sqft_living15_scaled
2000
1500
1000
500
0
0.0
0.2
0.4
0.6
0.8
1.0

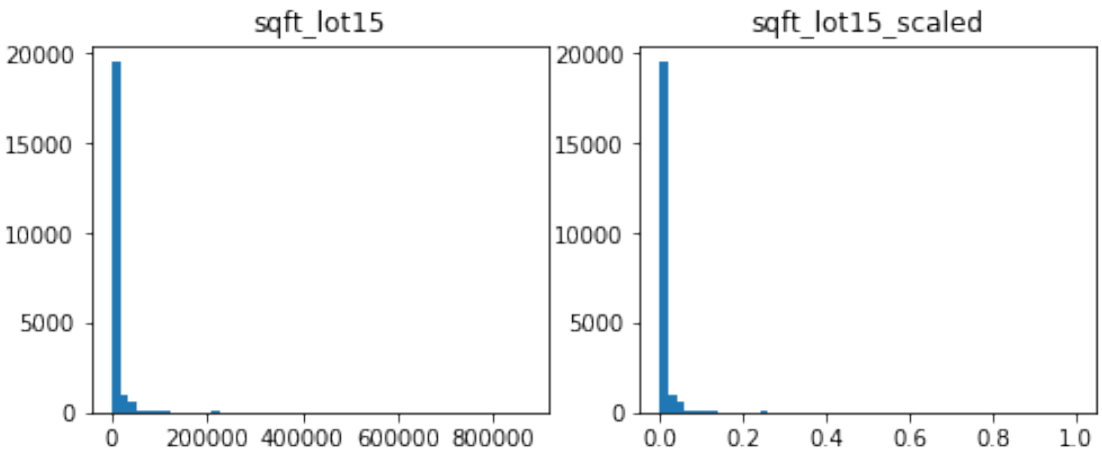
sqft_lot15
20000
15000
10000
5000
0
0
200000
400000
600000
800000

sqft_lot15_scaled
20000
15000
10000
5000
0
0.0
0.2
0.4
0.6
0.8
1.0

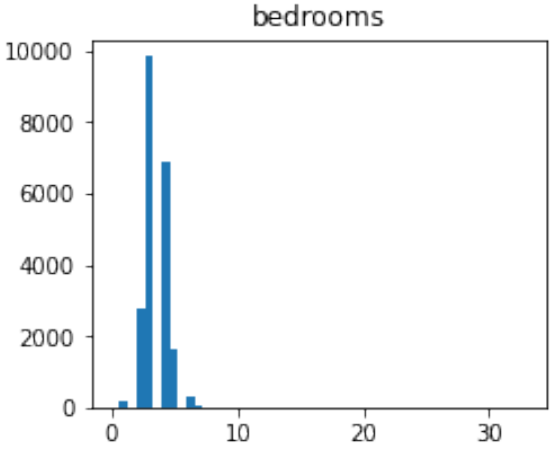
bedrooms
10000
8000
6000
4000
2000
0
0
10
20
30

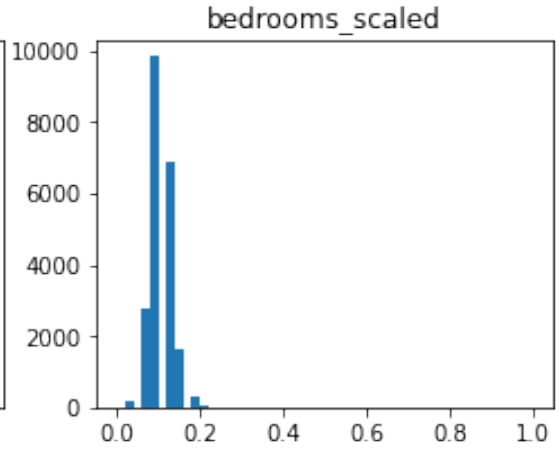
bedrooms_scaled
10000
8000
6000
4000
2000
0
0.0
0.2
0.4
0.6
0.8
1.0

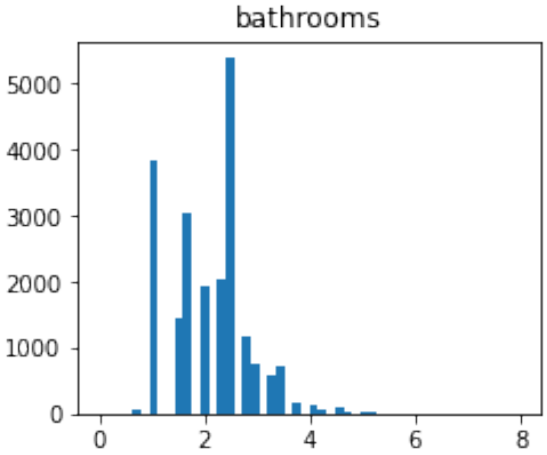
bathrooms
5000
4000
3000
2000
1000
0
0
2
4
6
8

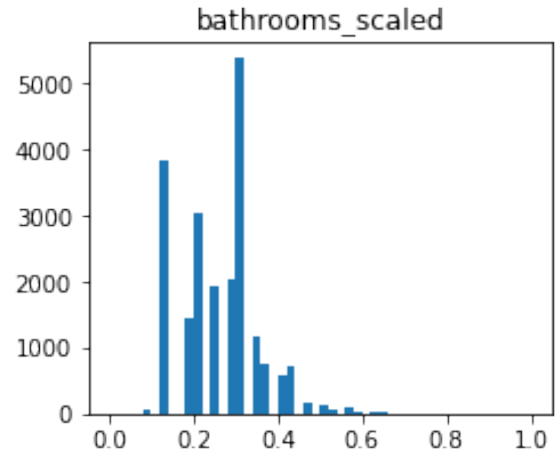
bathrooms_scaled
5000
4000
3000
2000
1000
0
0.0
0.2
0.4
0.6
0.8
1.0

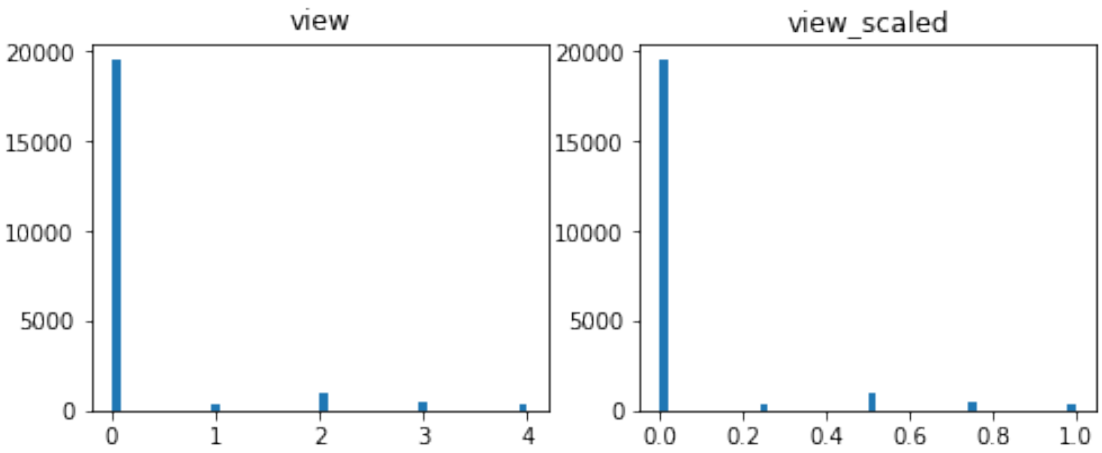
view
20000
15000
10000
5000
0
0
1
2
3
4

view_scaled
20000
15000
10000
5000
0
0.0
0.2
0.4
0.6
0.8
1.0

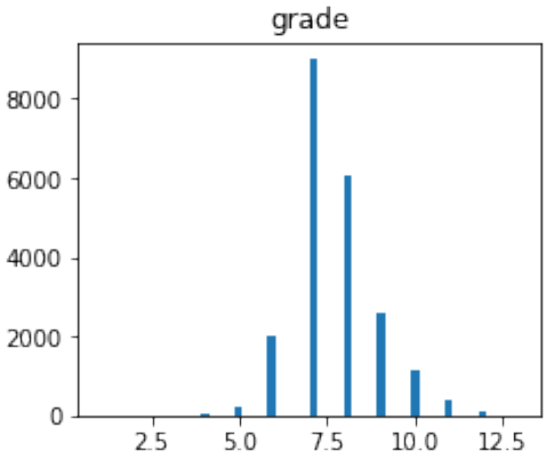
grade
8000
6000
4000
2000
0
2.5
5.0
7.5
10.0
12.5

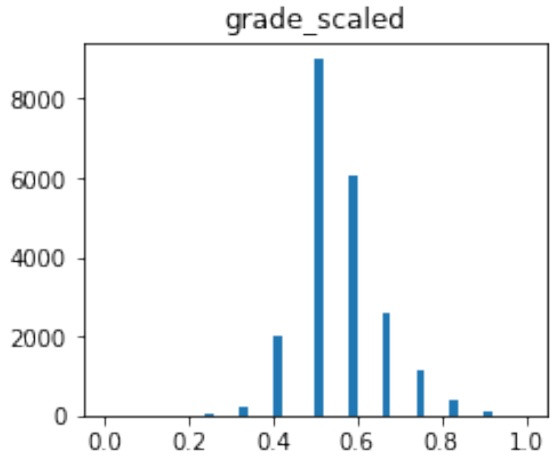
grade_scaled
8000
6000
4000
2000
0
0.0
0.2
0.4
0.6
0.8
1.0

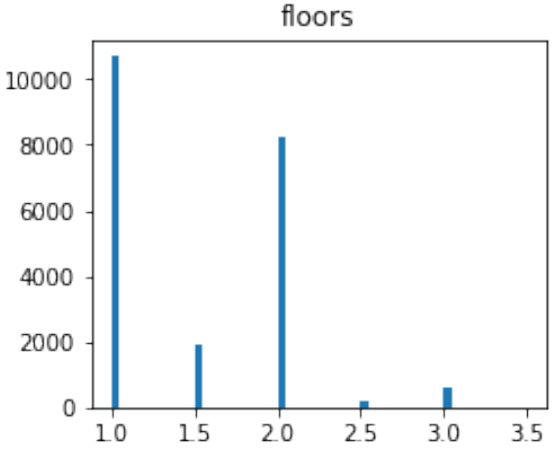
floors
10000
8000
6000
4000
2000
0
1.0
1.5
2.0
2.5
3.0
3.5

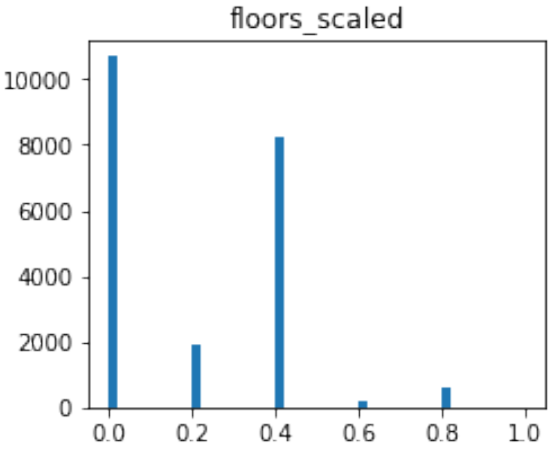
floors_scaled
10000
8000
6000
4000
2000
0
0.0
0.2
0.4
0.6
0.8
1.0

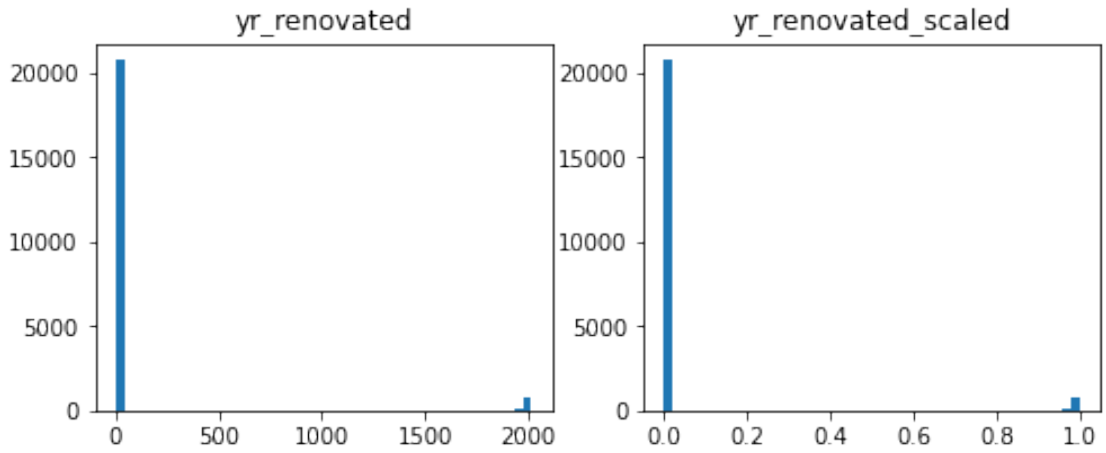

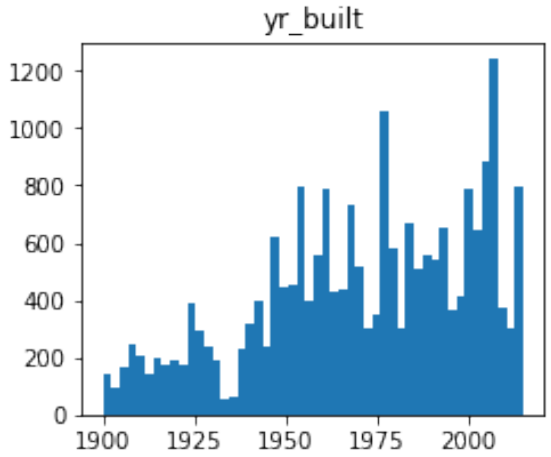

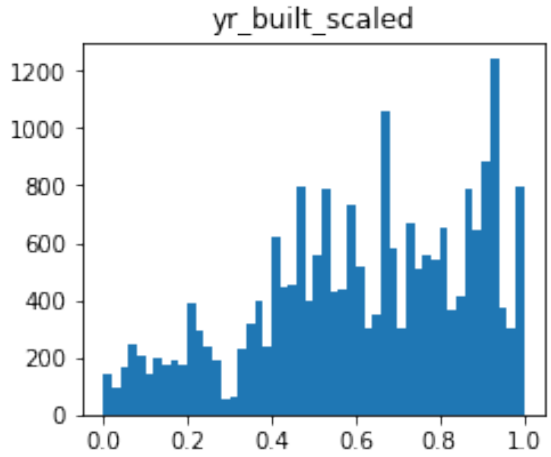

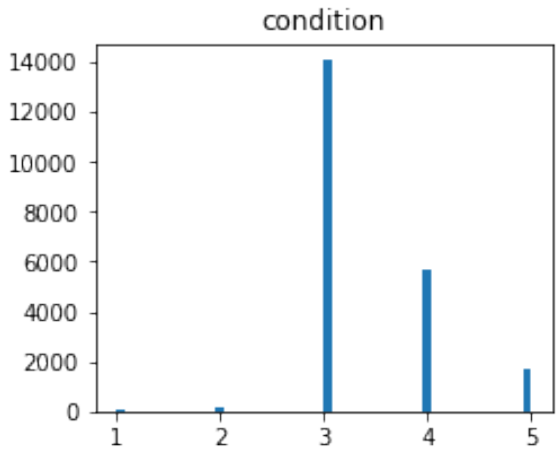

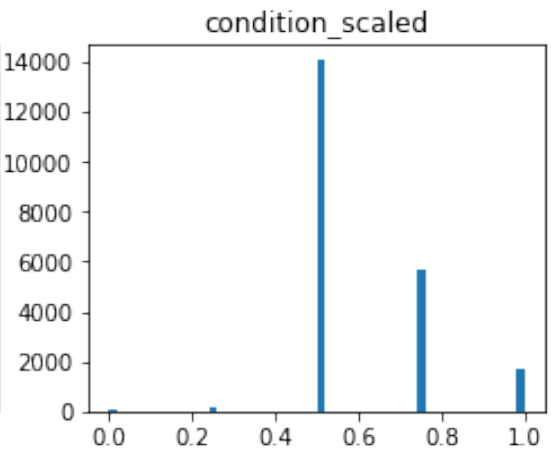

Удалим стаыре столбцы.

[18]:
```
data.drop(scale_cols, axis=1, inplace=True)
```

[19]:
```
data.head()
```

[19]:

	price	waterfront	zipcode	sqft_living_scaled	sqft_lot_scaled	sqft_above_scaled	sqft_basement_scaled	lat_scaled	long_scaled	sqft_living15_scaled	sqft_lot15_scaled	bedrooms_scaled	bathrooms_scaled	view_scaled	grade_scaled	floors_scaled	yr_renovated_scaled	yr_built_scaled	condition_scaled
0	221900.0	0	98178	0.067170	0.003108	0.097588	0.000000	0.571498	0.217608	0.161934	0.005742	0.090909	0.12500	0.0	0.500000	0.0	0.000000	0.478261	0.5
1	538000.0	0	98125	0.172075	0.004072	0.206140	0.082988	0.908959	0.166113	0.222165	0.008027	0.090909	0.28125	0.0	0.500000	0.4	0.988089	0.443478	0.5
2	180000.0	0	98028	0.036226	0.005743	0.052632	0.000000	0.936143	0.237542	0.399415	0.008513	0.060606	0.12500	0.0	0.416667	0.0	0.000000	0.286957	0.5
3	604000.0	0	98136	0.126038	0.002714	0.083333	0.188797	0.586939	0.104651	0.165376	0.004996	0.121212	0.37500	0.0	0.500000	0.0	0.000000	0.565217	1.0
4	510000.0	0	98074	0.104906	0.004579	0.152412	0.000000	0.741354	0.393688	0.241094	0.007871	0.090909	0.25000	0.0	0.583333	0.0	0.000000	0.756522	0.5

5 Проведение корреляционного анализа данных. Формирование промежуточных выводов о возможности построения моделей машинного обучения

[20]:
```
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

[20]: <AxesSubplot:>

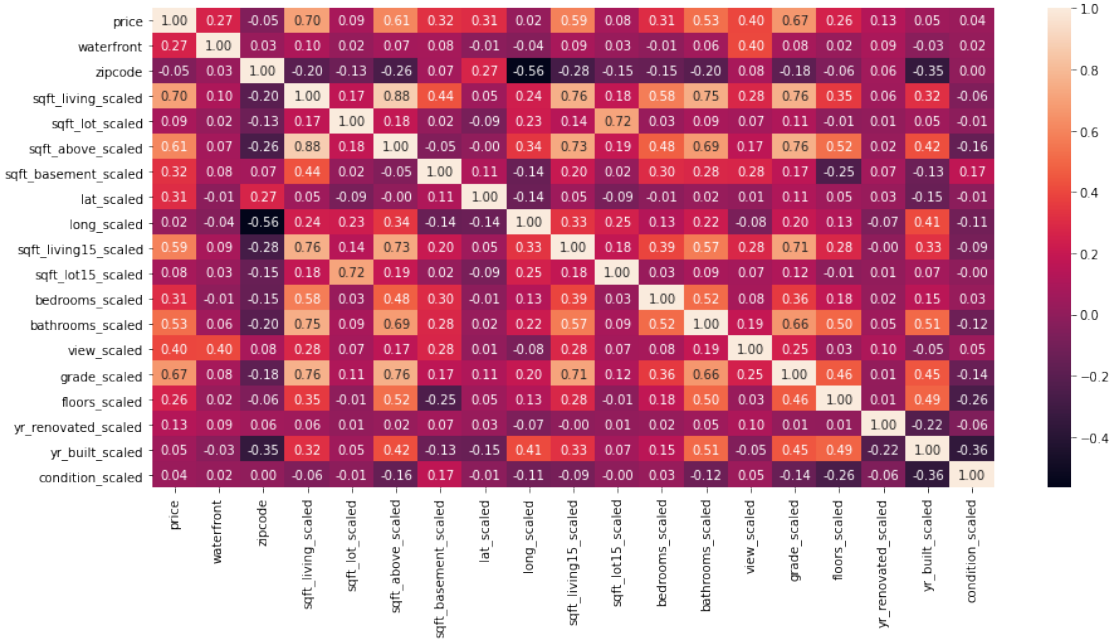

Удалим столбцы, которые плохо коррелируют с целевым признаком ‘price’

[21]:
```
data.drop(['long_scaled' , 'zipcode', 'yr_built_scaled', 'condition_scaled',
 ↪'sqft_lot_scaled', 'sqft_lot15_scaled'], axis=1, inplace=True)
```

[22]:
```
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

[22]: <AxesSubplot:>

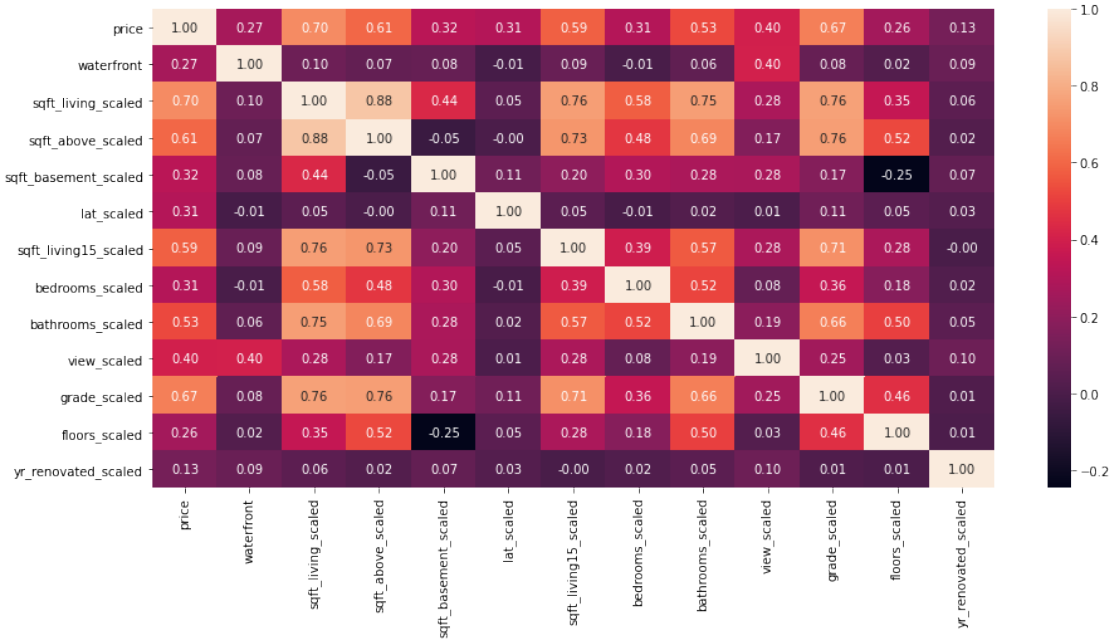

Вывод: * Корреляционные матрицы для исходных и масштабированных данных совпадают. * Целевой признак ‘price’ хорошо коррелирует с ‘grade_scaled’, ‘sqft_living_scaled’, ‘sqft_living15_scaled’, ‘sqft_above_scaled’, ‘bathrooms_scaled’, их точно надо оставить в модели регрессии * Признаки ‘long_scaled’ , ‘zipcode’, ‘yr_built’, ‘condition’, ‘sqft_lot_scaled’, ‘sqft_lot15_scaled’ почти не коррелируют с целевым признаком, их лучше удалить из модели * Большие по модулю значения коэффициентов корреляции свидетельствуют о значимой корреляции между исходными признаками и целевым признаком. На основании корреляционной матрицы можно сделать вывод о том, что данные позволяют построить модель машинного обучения.

6 Выбор метрик для последующей оценки качества моделей.

В качестве метрик для решения задачи регрессии будем испсользовать: Mean Absolute Error, Mean Squared Error и r2 оценку.

6.1 Сохранение и визуализация метрик

Разработаем класс, который поможет нам хранить метрики, их значения и визуализировать их.

[23]:
```
class MetricLogger:

    def __init__(self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
            'value': pd.Series([], dtype='float')})

    def add(self, metric, alg, value):
        """
        Добавление значения
        """
```

```
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].index,
↪inplace = True)
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore_index=True)

    def get_data_for_metric(self, metric, ascending=True):
        """
        Формирование данных с фильтром по метрике
        """
        temp_data = self.df[self.df['metric']==metric]
        temp_data_2 = temp_data.sort_values(by='value', ascending=ascending)
        return temp_data_2['alg'].values, temp_data_2['value'].values

    def plot(self, str_header, metric, ascending=True, figsize=(5, 5)):
        """
        Вывод графика
        """
        array_labels, array_metric = self.get_data_for_metric(metric, ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
        rects = ax1.barh(pos, array_metric,
                         align='center',
                         height=0.5,
                         tick_label=array_labels)
        ax1.set_title(str_header)
        for a,b in zip(pos, array_metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        plt.show()
```

7 Выбор наиболее подходящих моделей для решения задачи классификации или регрессии.

Для задачи регрессии будем использовать следующие модели:

- Линейная регрессия
- Метод ближайших соседей
- Машина опорных векторов (линейный алгоритм)
- Решающее дерево
- Случайный лес
- Градиентный бустинг

8 Формирование обучающей и тестовой выборок на основе исходного набора данных

[24]:
```
data.columns
```

[24]:
```
Index(['price', 'waterfront', 'sqft_living_scaled', 'sqft_above_scaled',
       'sqft_basement_scaled', 'lat_scaled', 'sqft_living15_scaled',
       'bedrooms_scaled', 'bathrooms_scaled', 'view_scaled', 'grade_scaled',
       'floors_scaled', 'yr_renovated_scaled'],
      dtype='object')
```

[25]:
```
feature_cols = [
    'bedrooms_scaled', 'bathrooms_scaled', 'floors_scaled', 'waterfront',
 ↪'view_scaled',
    'grade_scaled', 'yr_renovated_scaled', 'sqft_living_scaled', 'sqft_above_scaled',
    'sqft_basement_scaled', 'lat_scaled', 'sqft_living15_scaled'
]
data_X = data.loc[:,feature_cols]
data_Y = data.loc[:, 'price']
data_X_train, data_X_test, data_y_train, data_y_test = train_test_split(data_X,
 ↪data_Y,test_size=0.2, random_state=1)
```

9 Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки.

[26]:
```
# Модели
regr_models = {'LR': LinearRegression(),
               'KNN_1':KNeighborsRegressor(n_neighbors=1),
               'LinearSVR':LinearSVR(C=1.0),
               'Tree':DecisionTreeRegressor(),
               'RF':RandomForestRegressor(),
               'GB':GradientBoostingRegressor()}
```

[27]:
```
# Сохранение метрик
regrMetricLogger = MetricLogger()
```

[28]:
```
def regr_train_model(model_name, model, regrMetricLogger):
    model.fit(data_X_train, data_y_train)
    y_pred = model.predict(data_X_test)

    mae = mean_absolute_error(data_y_test, y_pred)
    mse = mean_squared_error(data_y_test, y_pred)
    r2 = r2_score(data_y_test, y_pred)
```

```
    regrMetricLogger.add('MAE', model_name, mae)
    regrMetricLogger.add('MSE', model_name, mse)
    regrMetricLogger.add('R2', model_name, r2)

    print('{} \t MAE={}, MSE={}, R2={}'.format(
        model_name, round(mae, 3), round(mse, 3), round(r2, 3)))
```

[29]:
```
for model_name, model in regr_models.items():
    regr_train_model(model_name, model, regrMetricLogger)
```

```
LR       MAE=136653.422, MSE=60599347912.745, R2=0.649
KNN_1    MAE=117071.057, MSE=55480600711.547, R2=0.679
LinearSVR        MAE=514663.235, MSE=435404175784.022, R2=-1.523
Tree     MAE=125079.57, MSE=60957821930.478, R2=0.647
RF       MAE=91576.642, MSE=32389789387.025, R2=0.812
GB       MAE=94569.69, MSE=32432160464.488, R2=0.812
```

10 Подбор гиперпараметров для выбранных моделей. Рекомендуется использовать методы кросс-валидации. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.

[31]:
```
kn_n_range = np.array(range(1,15,1))
kn_tuned_parameters = [{'n_neighbors': kn_n_range}]
kn_tuned_parameters
```

[31]:
```
[{'n_neighbors': array([ 1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13,
14])}]
```

[32]:
```
%%time
gs_kn = GridSearchCV(KNeighborsRegressor(), kn_tuned_parameters, cv=5,
 ↪scoring='neg_mean_squared_error')
gs_kn.fit(data_X_train, data_y_train)
```

```
CPU times: user 49.7 s, sys: 4.3 ms, total: 49.7 s
Wall time: 49.8 s
```

[32]:
```
GridSearchCV(cv=5, estimator=KNeighborsRegressor(),
             param_grid=[{'n_neighbors': array([ 1,  2,  3,  4,  5,  6,  7,  8,
9, 10, 11, 12, 13, 14])}],
             scoring='neg_mean_squared_error')
```

[33]:
```
# Лучшая модель
gs_kn.best_estimator_
```

[33]:
```
KNeighborsRegressor(n_neighbors=10)
```

[37]:
```
# Изменение качества на тестовой выборке в зависимости от K-соседей
plt.plot(kn_n_range, gs_kn.cv_results_['mean_test_score'])
```

[37]:
```
[<matplotlib.lines.Line2D at 0x7efcc11ffcd0>]
```

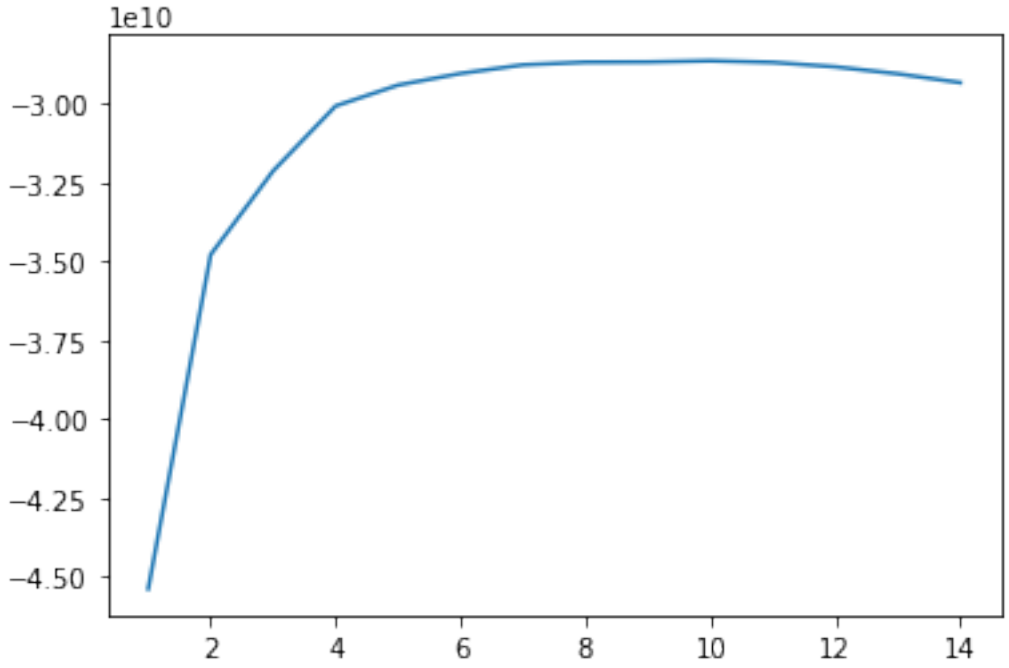

[43]:
```
lsvr_c_range =  np.array(range(1,100000, 10000))
lsvr_tuned_parameters = [{'C': lsvr_c_range}]
lsvr_tuned_parameters
```

[43]:
```
[{'C': array([    1, 10001, 20001, 30001, 40001, 50001, 60001, 70001, 80001,
         90001])}]
```

[39]:
```
%%time
gs_lsvr = GridSearchCV(LinearSVR(), lsvr_tuned_parameters, cv=5,
 ↪scoring='neg_mean_squared_error')
gs_lsvr.fit(data_X_train, data_y_train)
```

```
CPU times: user 7.12 s, sys: 5.25 s, total: 12.4 s
Wall time: 3.48 s
```

[39]:
```
GridSearchCV(cv=5, estimator=LinearSVR(),
             param_grid=[{'C': array([    1, 10001, 20001, 30001, 40001, 50001,
60001, 70001, 80001,
       90001])}],
             scoring='neg_mean_squared_error')
```

[40]:
```
# Лучшая модель
gs_lsvr.best_estimator_
```

[40]:
```
LinearSVR(C=90001)
```

[45]:
```
# Изменение качества на тестовой выборке в зависимости от C
plt.plot(lsvr_c_range, gs_lsvr.cv_results_['mean_test_score'])
```

[45]:
```
[<matplotlib.lines.Line2D at 0x7efcc03a24f0>]
```

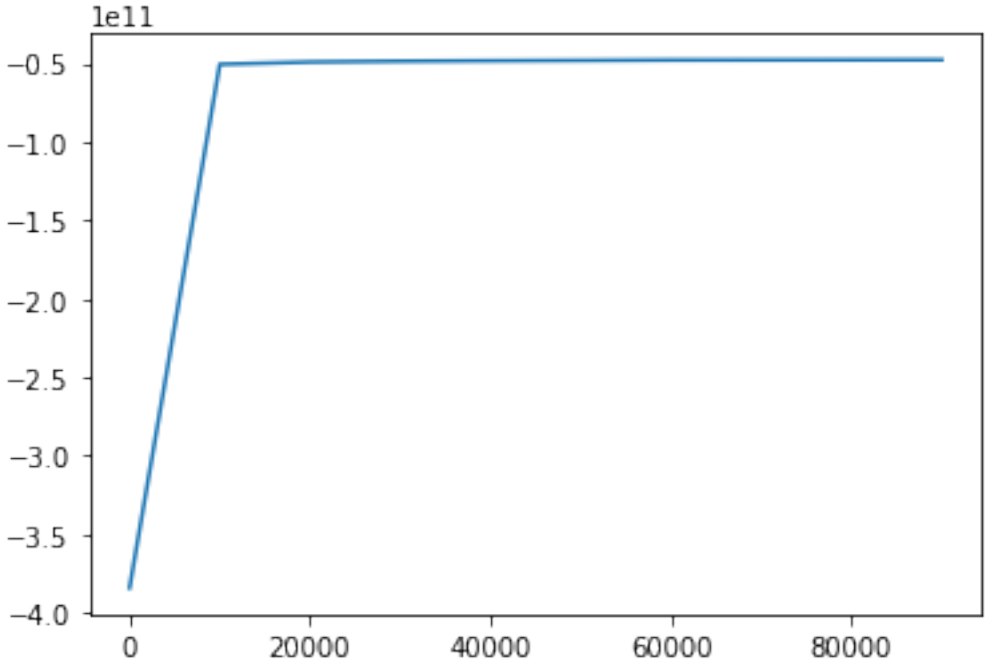

[87]:
```
tree_depth_range = np.array(range(3,11,1))
tree_tuned_parameters = [{'max_depth': tree_depth_range}]
tree_tuned_parameters
```

[87]:
```
[{'max_depth': array([ 3,  4,  5,  6,  7,  8,  9, 10])}]
```

[88]:
```
%%time
gs_tree = GridSearchCV(DecisionTreeRegressor(), tree_tuned_parameters, cv=5,
 ↪scoring='neg_mean_squared_error')
gs_tree.fit(data_X_train, data_y_train)
```

```
CPU times: user 2.05 s, sys: 21 µs, total: 2.05 s
Wall time: 2.09 s
```

[88]:
```
GridSearchCV(cv=5, estimator=DecisionTreeRegressor(),
             param_grid=[{'max_depth': array([ 3,  4,  5,  6,  7,  8,  9,
10])}],
```

```
                scoring='neg_mean_squared_error')
```

[49]:
```
# Лучшая модель
gs_tree.best_estimator_
```

[49]:
```
DecisionTreeRegressor(max_depth=9)
```

[50]:
```
# Изменение качества на тестовой выборке в зависимости от глубины дерева
plt.plot(tree_depth_range, gs_tree.cv_results_['mean_test_score'])
```

[50]:
```
[<matplotlib.lines.Line2D at 0x7efcbfa012b0>]
```

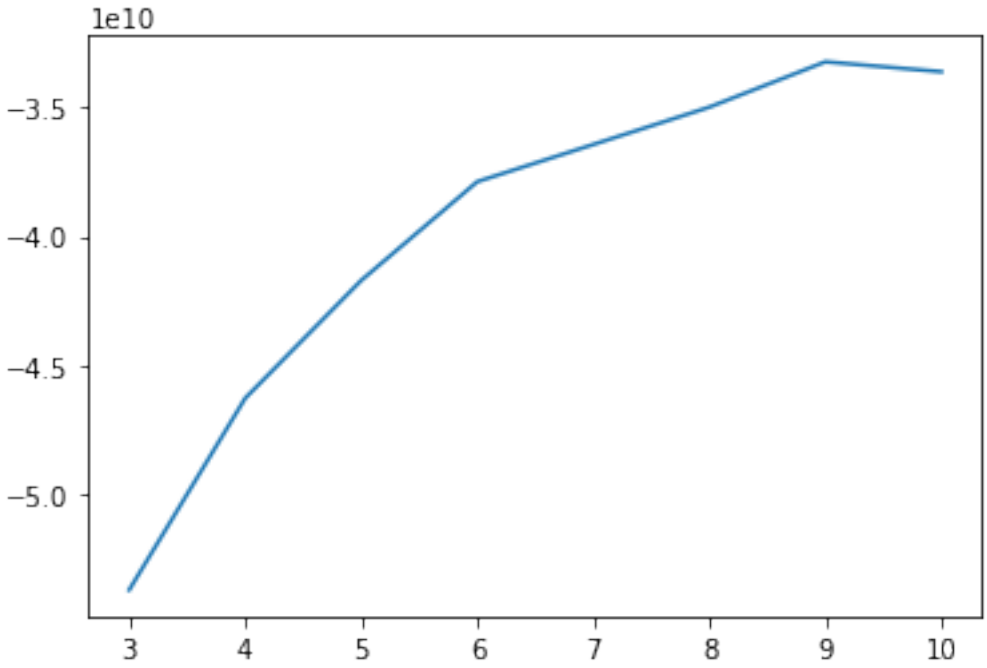

[73]:
```
rf_n_range = np.array(range(200,500,100))
rf_tuned_parameters = [{'n_estimators': rf_n_range}]
rf_tuned_parameters
```

[73]:
```
[{'n_estimators': array([200, 300, 400])}]
```

[80]:
```
%%time
gs_rf = GridSearchCV(RandomForestRegressor(), rf_tuned_parameters, cv=5,
 ↪scoring='neg_mean_squared_error', n_jobs=-1)
gs_rf.fit(data_X_train, data_y_train)
```

```
CPU times: user 19.2 s, sys: 251 ms, total: 19.4 s
Wall time: 2min 49s
```

[80]:
```
GridSearchCV(cv=5, estimator=RandomForestRegressor(), n_jobs=-1,
             param_grid=[{'n_estimators': array([200, 300, 400])}],
             scoring='neg_mean_squared_error')
```

[81]:
```
# Лучшая модель
gs_rf.best_estimator_
```

[81]:
```
RandomForestRegressor(n_estimators=200)
```

[82]:
```
# Изменение качества на тестовой выборке в зависимости от n_estimators
plt.plot(rf_n_range, gs_rf.cv_results_['mean_test_score'])
```

[82]:
```
[<matplotlib.lines.Line2D at 0x7efcc88bf910>]
```

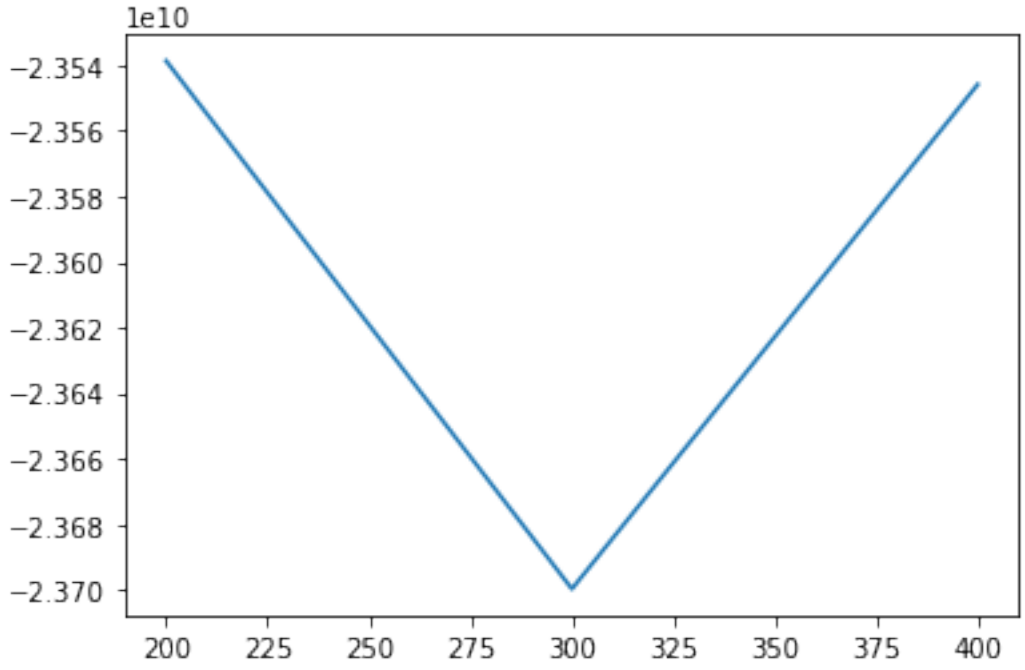

[83]:
```
%%time
gs_gb = GridSearchCV(GradientBoostingRegressor(), rf_tuned_parameters, cv=5,
 ↪scoring='neg_mean_squared_error', n_jobs=-1)
gs_gb.fit(data_X_train, data_y_train)
```

```
CPU times: user 9.77 s, sys: 6.56 ms, total: 9.78 s
Wall time: 45.2 s
```

[83]:
```
GridSearchCV(cv=5, estimator=GradientBoostingRegressor(), n_jobs=-1,
             param_grid=[{'n_estimators': array([200, 300, 400])}],
             scoring='neg_mean_squared_error')
```

[84]:
```
# Лучшая модель
gs_gb.best_estimator_
```

[84]:
```
GradientBoostingRegressor(n_estimators=400)
```

[85]:
```
# Изменение качества на тестовой выборке в зависимости от n_estimators
plt.plot(rf_n_range, gs_gb.cv_results_['mean_test_score'])
```

[85]:
```
[<matplotlib.lines.Line2D at 0x7efcc8db0820>]
```

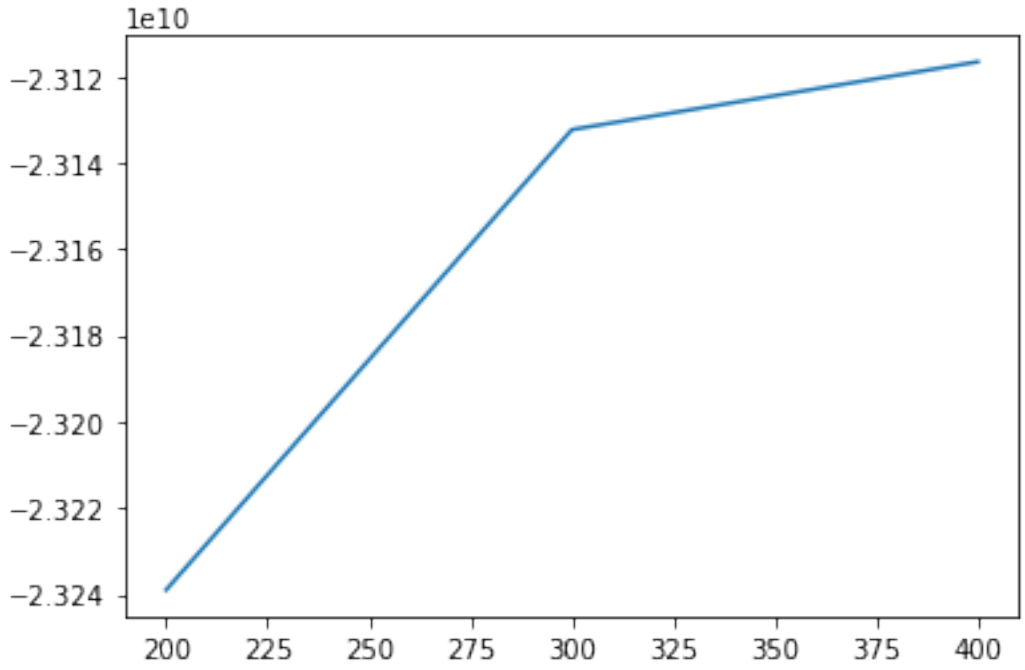

11 Повторение пункта 8 для найденных оптимальных значений гиперпараметров. Сравнение качества полученных моделей с качеством baseline-моделей.

[89]:
```
regr_models_grid = {
    'KNN(best)':gs_kn.best_estimator_,
    'Tree(best)':gs_tree.best_estimator_,
    'LinearSVR(best)':gs_lsvr.best_estimator_,
    'RF(best)':gs_rf.best_estimator_,
    'GB(best)':gs_gb.best_estimator_
                    }
```

[90]:
```
for model_name, model in regr_models_grid.items():
    regr_train_model(model_name, model, regrMetricLogger)
```

```
KNN(best)        MAE=96657.319, MSE=47779449527.494, R2=0.723
```

```
Tree(best)       MAE=108504.681, MSE=42722488692.848, R2=0.752
LinearSVR(best)          MAE=129267.13, MSE=71875871300.374, R2=0.584
RF(best)         MAE=91524.206, MSE=33475421722.717, R2=0.806
GB(best)         MAE=92487.687, MSE=30236231505.354, R2=0.825
```

12 Формирование выводов о качестве построенных моделей на основе выбранных метрик. Результаты сравнения качества рекомендуется отобразить в виде графиков и сделать выводы в форме текстового описания. Рекомендуется построение графиков обучения и валидации, влияния значений гиперпарметров на качество моделей и т.д.

[91]:
```
# Метрики качества модели
regr_metrics = regrMetricLogger.df['metric'].unique()
regr_metrics
```

[91]:
```
array(['MAE', 'MSE', 'R2'], dtype=object)
```

[92]:
```
regrMetricLogger.plot('Метрика: ' + 'MAE', 'MAE', ascending=False, figsize=(7, 6))
```

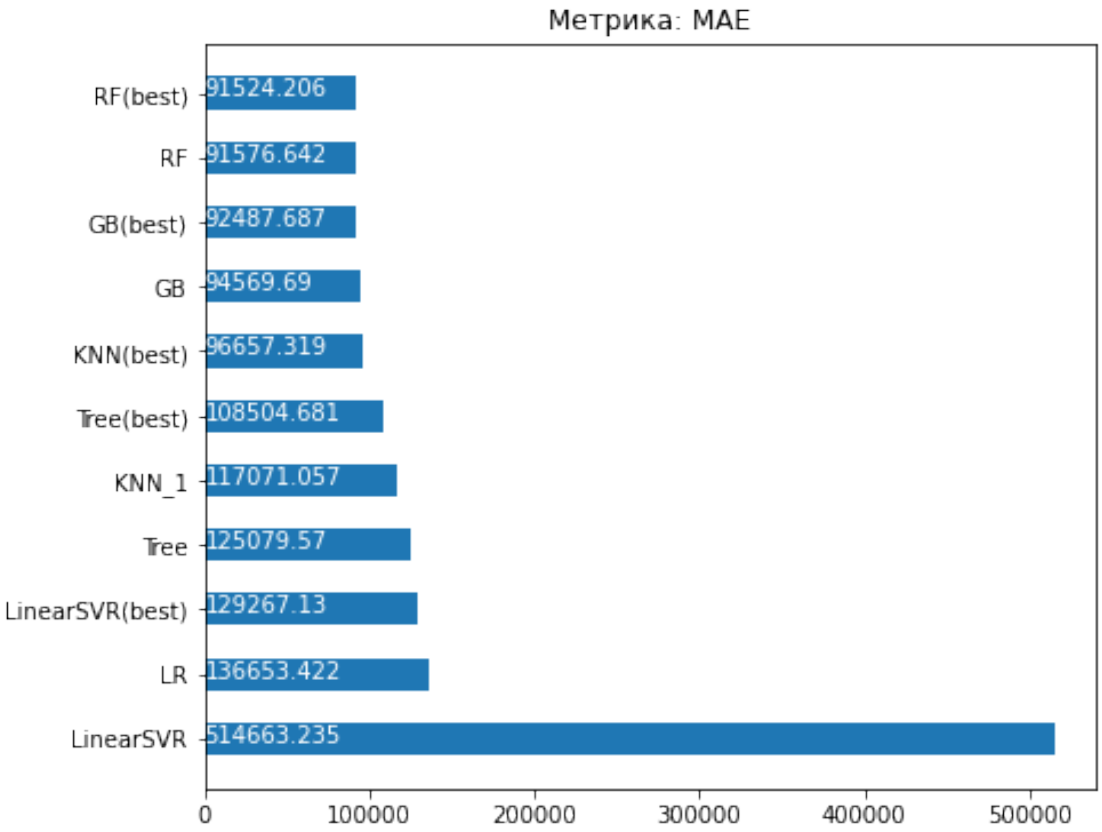

[93]:
```
regrMetricLogger.plot('Метрика: ' + 'MSE', 'MSE', ascending=False, figsize=(7, 6))
```

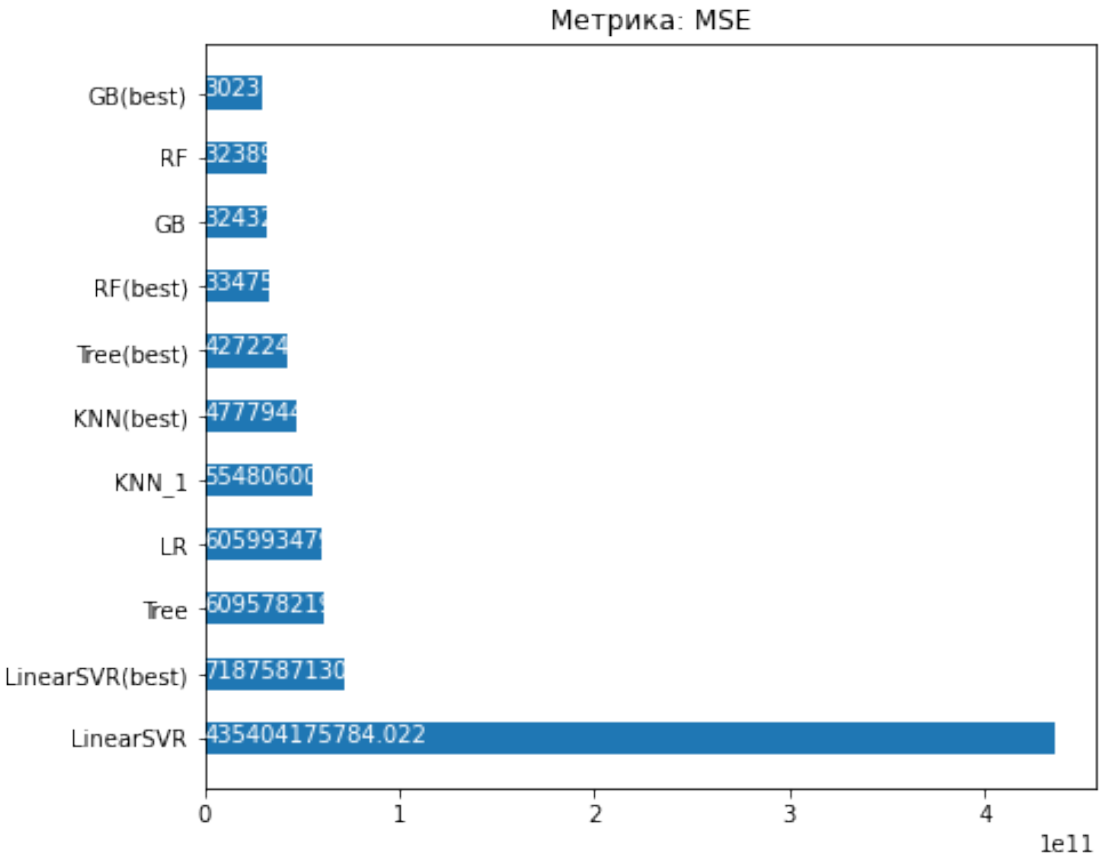

[94]:
```
regrMetricLogger.plot('Метрика: ' + 'R2', 'R2', ascending=True, figsize=(7, 6))
```

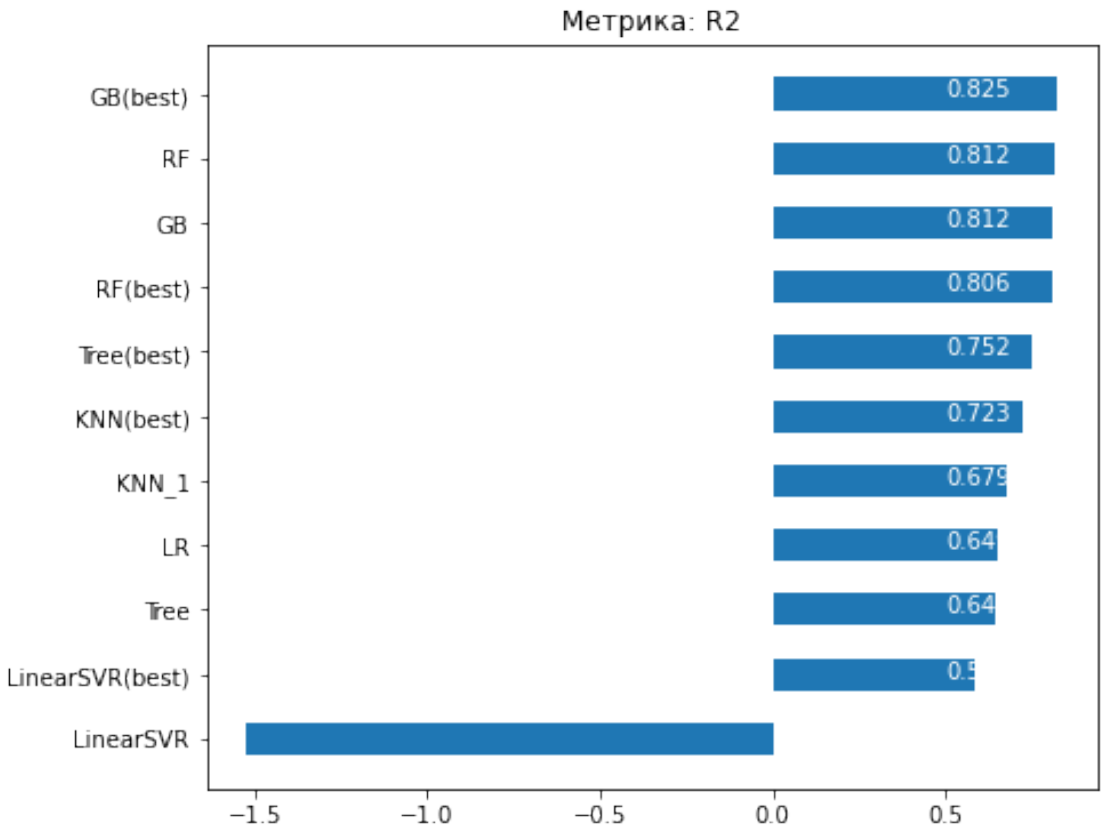

13 AutoML

[76]:
```
import autosklearn.regression
```

[78]:
```
automl = autosklearn.regression.AutoSklearnRegressor(time_left_for_this_task=120,
    ↪per_run_time_limit=30)
automl.fit(data_X_train, data_y_train)
```

[78]:
```
AutoSklearnRegressor(per_run_time_limit=30, time_left_for_this_task=120)
```

[79]:
```
predictions = automl.predict(data_X_test)
print("AutoML R2 score:", r2_score(data_y_test, predictions))
```

```
AutoML R2 score: 0.808234600610789
```

[95]:
```
print(automl.show_models())
```

```
[(0.680000, SimpleRegressionPipeline({'data_preprocessing:categorical_transforme
r:categorical_encoding:__choice__': 'no_encoding',
'data_preprocessing:categorical_transformer:category_coalescence:__choice__':
'no_coalescense',
'data_preprocessing:numerical_transformer:imputation:strategy': 'mean',
'data_preprocessing:numerical_transformer:rescaling:__choice__':
```

```
'robust_scaler', 'feature_preprocessor:__choice__': 'feature_agglomeration',
'regressor:__choice__': 'gradient_boosting',
'data_preprocessing:numerical_transformer:rescaling:robust_scaler:q_max':
0.7727512096172742,
'data_preprocessing:numerical_transformer:rescaling:robust_scaler:q_min':
0.22461598115758682, 'feature_preprocessor:feature_agglomeration:affinity':
'manhattan', 'feature_preprocessor:feature_agglomeration:linkage': 'complete',
'feature_preprocessor:feature_agglomeration:n_clusters': 21,
'feature_preprocessor:feature_agglomeration:pooling_func': 'max',
'regressor:gradient_boosting:early_stop': 'train',
'regressor:gradient_boosting:l2_regularization': 2.208787572338781e-05,
'regressor:gradient_boosting:learning_rate': 0.036087332404571744,
'regressor:gradient_boosting:loss': 'least_squares',
'regressor:gradient_boosting:max_bins': 255,
'regressor:gradient_boosting:max_depth': 'None',
'regressor:gradient_boosting:max_leaf_nodes': 64,
'regressor:gradient_boosting:min_samples_leaf': 3,
'regressor:gradient_boosting:scoring': 'loss',
'regressor:gradient_boosting:tol': 1e-07,
'regressor:gradient_boosting:n_iter_no_change': 18},
dataset_properties={
  'task': 4,
  'sparse': False,
  'multioutput': False,
  'target_type': 'regression',
  'signed': False})),
(0.220000, SimpleRegressionPipeline({'data_preprocessing:categorical_transformer
:categorical_encoding:__choice__': 'one_hot_encoding',
'data_preprocessing:categorical_transformer:category_coalescence:__choice__':
'minority_coalescer',
'data_preprocessing:numerical_transformer:imputation:strategy': 'mean',
'data_preprocessing:numerical_transformer:rescaling:__choice__': 'none',
'feature_preprocessor:__choice__': 'polynomial', 'regressor:__choice__':
'gradient_boosting', 'data_preprocessing:categorical_transformer:category_coales
cence:minority_coalescer:minimum_fraction': 0.010000000000000004,
'feature_preprocessor:polynomial:degree': 3,
'feature_preprocessor:polynomial:include_bias': 'True',
'feature_preprocessor:polynomial:interaction_only': 'True',
'regressor:gradient_boosting:early_stop': 'train',
'regressor:gradient_boosting:l2_regularization': 6.085630700044881e-10,
'regressor:gradient_boosting:learning_rate': 0.12392806728650493,
'regressor:gradient_boosting:loss': 'least_squares',
'regressor:gradient_boosting:max_bins': 255,
'regressor:gradient_boosting:max_depth': 'None',
'regressor:gradient_boosting:max_leaf_nodes': 31,
'regressor:gradient_boosting:min_samples_leaf': 25,
'regressor:gradient_boosting:scoring': 'loss',
'regressor:gradient_boosting:tol': 1e-07,
```

```
'regressor:gradient_boosting:n_iter_no_change': 7},
dataset_properties={
  'task': 4,
  'sparse': False,
  'multioutput': False,
  'target_type': 'regression',
  'signed': False})),
(0.100000, SimpleRegressionPipeline({'data_preprocessing:categorical_transformer
:categorical_encoding:__choice__': 'no_encoding',
'data_preprocessing:categorical_transformer:category_coalescence:__choice__':
'minority_coalescer',
'data_preprocessing:numerical_transformer:imputation:strategy': 'mean',
'data_preprocessing:numerical_transformer:rescaling:__choice__': 'none',
'feature_preprocessor:__choice__': 'polynomial', 'regressor:__choice__':
'ard_regression', 'data_preprocessing:categorical_transformer:category_coalescen
ce:minority_coalescer:minimum_fraction': 0.00829519231049576,
'feature_preprocessor:polynomial:degree': 2,
'feature_preprocessor:polynomial:include_bias': 'False',
'feature_preprocessor:polynomial:interaction_only': 'False',
'regressor:ard_regression:alpha_1': 4.7044575285722365e-05,
'regressor:ard_regression:alpha_2': 0.000629863807127318,
'regressor:ard_regression:fit_intercept': 'True',
'regressor:ard_regression:lambda_1': 7.584067704707025e-10,
'regressor:ard_regression:lambda_2': 3.923255608410879e-08,
'regressor:ard_regression:n_iter': 300,
'regressor:ard_regression:threshold_lambda': 4052.403778957396,
'regressor:ard_regression:tol': 0.009359388994186051},
dataset_properties={
  'task': 4,
  'sparse': False,
  'multioutput': False,
  'target_type': 'regression',
  'signed': False})),
]
```

14 Код для макета WEB-версии

```python
#!/usr/bin/env python

import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from typing import Dict, Tuple
from IPython.display import Image

import streamlit as st

```

```
from sklearn.preprocessing import MinMaxScaler
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score, classification_
↪report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import plot_confusion_matrix
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squared_log_
↪error, median_absolute_error, r2_score
from sklearn.metrics import roc_curve, roc_auc_score
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor
from sklearn.ensemble import GradientBoostingClassifier, GradientBoostingRegressor

class MetricLogger:

    def __init__(self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
            'value': pd.Series([], dtype='float')})

    def add(self, metric, alg, value):
        """
        Добавление значения
        """
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].index,
↪inplace = True)
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore_index=True)

    def get_data_for_metric(self, metric, ascending=True):
        """
        Формирование данных с фильтром по метрике
        """
        temp_data = self.df[self.df['metric']==metric]
        temp_data_2 = temp_data.sort_values(by='value', ascending=ascending)
        return temp_data_2['alg'].values, temp_data_2['value'].values

    def plot(self, str_header, metric, ascending=True, figsize=(5, 5)):
        """
```

```
        Вывод графика
        """
        array_labels, array_metric = self.get_data_for_metric(metric, ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
        rects = ax1.barh(pos, array_metric,
                         align='center',
                         height=0.5,
                         tick_label=array_labels)
        ax1.set_title(str_header)
        for a,b in zip(pos, array_metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        return fig

def regr_train_model(model_name, model, regrMetricLogger):
    model.fit(data_X_train, data_y_train)
    y_pred = model.predict(data_X_test)

    mae = mean_absolute_error(data_y_test, y_pred)
    mse = mean_squared_error(data_y_test, y_pred)
    r2 = r2_score(data_y_test, y_pred)

    regrMetricLogger.add('MAE', model_name, mae)
    regrMetricLogger.add('MSE', model_name, mse)
    regrMetricLogger.add('R2', model_name, r2)

    return '{} \t MAE={}, MSE={}, R2={}'.format(
        model_name, round(mae, 3), round(mse, 3), round(r2, 3))

@st.cache
def load_data():
    read_data = pd.read_csv("data/kc_house_data.csv", sep=',')
    read_data.drop(['id', 'date'], axis=1, inplace=True)
    return read_data


st.header('Датасет')
read_state = st.text('Чтение датасета...')
data = load_data().copy()
read_state.text('Датасет загружен!')
st.subheader('head:')
st.write(data.head())

regr_models = []


if st.sidebar.checkbox('Limit rows(for better performance)'):
    max_rows = st.sidebar.slider('Max rows', 200, len(data), 2000)
```

```
105     data = data.head(max_rows)
106 
107 if st.sidebar.checkbox('MinMaxScaler'):
108     scale_cols = ['sqft_living', 'sqft_lot', 'sqft_above',
109             'sqft_basement', 'lat', 'long',
110             'sqft_living15', 'sqft_lot15', 'bedrooms',
111             'bathrooms', 'view', 'grade', 'floors', 'yr_renovated', 'yr_built',
 ↪'condition'
112             ]
113     sc = MinMaxScaler()
114     sc_data = sc.fit_transform(data[scale_cols])
115     # Добавим масштабированные данные в набор данных
116     for i in range(len(scale_cols)):
117         col = scale_cols[i]
118         data[col] = sc_data[:,i]
119     st.subheader('Масштабированный датасет:')
120     st.write(data.head())
121 
122 test_size = st.sidebar.slider('test_size', 0.1, 0.9, value = 0.3)
123 
124 feature_cols = [
125     'bedrooms', 'bathrooms', 'floors', 'waterfront', 'view',
126     'grade', 'yr_renovated', 'sqft_living', 'sqft_above',
127     'sqft_basement', 'lat', 'sqft_living15'
128 ]
129 data_X = data.loc[:,feature_cols]
130 data_Y = data.loc[:, 'price']
131 data_X_train, data_X_test, data_y_train, data_y_test = train_test_split(data_X, data_
 ↪Y,test_size=test_size, random_state=1)
132 
133 # Сохранение метрик
134 regrMetricLogger = MetricLogger()
135 
136 if st.sidebar.checkbox('LinearRegression'):
137     regr_train_model('LR', LinearRegression(), regrMetricLogger)
138 
139 if st.sidebar.checkbox('KNeighborsRegression'):
140     n_neighbors = 5
141     n_neighbors = st.sidebar.slider("n_neighbors", 1, 100, value = 5)
142     regr_train_model('KNN', KNeighborsRegressor(n_neighbors=n_neighbors),
 ↪regrMetricLogger)
143     if st.sidebar.checkbox("KNeighborsRegression(Best)"):
144         n_neighbors_search_1 = st.sidebar.slider("n starts from", 1, 100)
145         n_neighbors_search_2 = st.sidebar.slider("n ends with", 1, 100, value=10)
146         n_neighbors_search_step = st.sidebar.slider("n step", 1, 100, 1)
147         n_range = np.array(range(n_neighbors_search_1, n_neighbors_search_2, n_neighbors_
 ↪search_step))
148         kn_tuned_parameters = [{'n_neighbors': n_range}]
```

```
149
150         gs_kn = GridSearchCV(KNeighborsRegressor(), kn_tuned_parameters, cv=5, scoring=
    ↪'neg_mean_squared_error')
151         gs_kn.fit(data_X_train, data_y_train)
152         regr_train_model('KNN(Best)', gs_kn.best_estimator_, regrMetricLogger)
153         st.subheader('Best model for KNeighborsRegressor:')
154         st.write(gs_kn.best_estimator_)
155 
156         fig, ax = plt.subplots(figsize=(5, 3))
157         ax.plot(n_range, gs_kn.cv_results_['mean_test_score'])
158         st.pyplot(fig)
159     st.sidebar.markdown("""---""")
160 
161 
162 if st.sidebar.checkbox('LinearSVR'):
163     regr_train_model('LinearSVR', LinearSVR(), regrMetricLogger)
164     if st.sidebar.checkbox('LinearSVR(Best)'):
165         c_start = st.sidebar.slider("c starts from", 1, 100000, value=1)
166         c_ends = st.sidebar.slider("c ends with", 1, 100000, value=10000)
167         c_step = st.sidebar.slider("c step", 1, 1000, value=1000)
168         lsvr_c_range = np.array(range(c_start, c_ends, c_step))
169         lsvr_tuned_params = [{'C': lsvr_c_range}]
170 
171         gs_lsvr = GridSearchCV(LinearSVR(), lsvr_tuned_params, cv=5, scoring='neg_mean_
    ↪squared_error')
172         gs_lsvr.fit(data_X_train, data_y_train)
173         regr_train_model('LinearSVR(Best)', gs_lsvr.best_estimator_, regrMetricLogger)
174         st.subheader('Best model for LinearSVR:')
175         st.write(gs_lsvr.best_estimator_)
176 
177         fig, ax = plt.subplots(figsize=(5, 3))
178         ax.plot(lsvr_c_range, gs_lsvr.cv_results_['mean_test_score'])
179         st.pyplot(fig)
180     st.sidebar.markdown("""---""")
181 
182 
183 if st.sidebar.checkbox('DecisionTreeRegressor'):
184     regr_train_model('Tree', DecisionTreeRegressor(), regrMetricLogger)
185     if st.sidebar.checkbox('DecisionTreeRegressor(Best)'):
186         depth_start = st.sidebar.slider("depth starts from", 1, 1000, value=3)
187         depth_end = st.sidebar.slider("depth ends with", 1, 1000, value=10)
188         depth_step = st.sidebar.slider("depth step", 1, 100, value=2)
189         depth_range = np.array(range(depth_start, depth_end, depth_step))
190         tree_pars = [{'max_depth': depth_range}]
191 
192         gs_tree = GridSearchCV(DecisionTreeRegressor(), tree_pars, cv=5, scoring='neg_
    ↪mean_squared_error')
193         gs_tree.fit(data_X_train, data_y_train)
```

```
        regr_train_model('Tree(Best)', gs_tree.best_estimator_, regrMetricLogger)
        st.subheader('Best model for DecisionTreeRegressor:')
        st.write(gs_tree.best_estimator_)

        fig, ax = plt.subplots(figsize=(5, 3))
        ax.plot(depth_range, gs_tree.cv_results_['mean_test_score'])
        st.pyplot(fig)
    st.sidebar.markdown("""---""")


if st.sidebar.checkbox('RandomForestRegressor'):
    regr_train_model('RF', RandomForestRegressor(), regrMetricLogger)
    if st.sidebar.checkbox('RandomForestRegressor(Best)'):
        n_estimators_search_1 = st.sidebar.slider("ne starts from", 100, 1000, value=100)
        n_estimators_search_2 = st.sidebar.slider("ne ends with", 1, 1000, value=101)
        n_estimators_search_step = st.sidebar.slider("ne step", 100, 1000, value=100)
        n_estimators_range = np.array(range(n_estimators_search_1, n_estimators_search_
↪2, n_estimators_search_step))
        rf_tuned_parameters = [{'n_estimators': n_estimators_range}]

        gs_rf = GridSearchCV(RandomForestRegressor(), rf_tuned_parameters, cv=5, scoring=
↪'neg_mean_squared_error')
        gs_rf.fit(data_X_train, data_y_train)
        regr_train_model('RF(Best)', gs_rf.best_estimator_, regrMetricLogger)
        st.subheader('Best model for RandomForestRegressor:')
        st.write(gs_rf.best_estimator_)

        fig, ax = plt.subplots(figsize=(5, 3))
        ax.plot(n_estimators_range, gs_rf.cv_results_['mean_test_score'])
        st.pyplot(fig)
    st.sidebar.markdown("""---""")


if st.sidebar.checkbox('GradientBoostingRegressor'):
    regr_train_model('GB', GradientBoostingRegressor(), regrMetricLogger)
    if st.sidebar.checkbox('GradientBoostingRegressor(Best)'):
        n_estimators_search_1 = st.sidebar.slider("nee starts from", 100, 1000,
↪value=100)
        n_estimators_search_2 = st.sidebar.slider("nee ends with", 1, 1000, value=101)
        n_estimators_search_step = st.sidebar.slider("nee step", 100, 1000, value=100)
        n_estimators_range = np.array(range(n_estimators_search_1, n_estimators_search_
↪2, n_estimators_search_step))
        gb_tuned_parameters = [{'n_estimators': n_estimators_range}]

        gs_gb = GridSearchCV(GradientBoostingRegressor(), gb_tuned_parameters, cv=5,
↪scoring='neg_mean_squared_error')
        gs_gb.fit(data_X_train, data_y_train)
```

```
        regr_train_model('GB(Best)', gs_gb.best_estimator_, regrMetricLogger)
        st.subheader('Best model for GradientBoostingRegressor:')
        st.write(gs_gb.best_estimator_)

        fig, ax = plt.subplots(figsize=(5, 3))
        ax.plot(n_estimators_range, gs_gb.cv_results_['mean_test_score'])
        st.pyplot(fig)
    st.sidebar.markdown("""---""")

st.sidebar.header('Metrics')
if st.sidebar.checkbox('MAE'):
    fig = regrMetricLogger.plot('Метрика: ' + 'MAE', 'MAE', ascending=False, figsize=(7,
 ↪6))
    st.pyplot(fig)

if st.sidebar.checkbox('MSE'):
    fig = regrMetricLogger.plot('Метрика: ' + 'MSE', 'MSE', ascending=False, figsize=(7,
 ↪6))
    st.pyplot(fig)

if st.sidebar.checkbox('r2'):
    fig = regrMetricLogger.plot('Метрика: ' + 'R2', 'R2', ascending=True, figsize=(7, 6))
    st.pyplot(fig)
```

15 Заключение

В ходе работы я исследовал несколько разных моделей машинного обучения(в т.ч. используя автоматический пакет AutoML) и создал макет веб-приложения, предназначенного для анализа данных.

Лучше всего себя показали ансамблевые модели градиентного бустинга и случаного леса. Самый лучший результат показывает модель градиентного бустинга(при n_estimators=400). Без подбора параметров модель случайного леса дает лучший результат. Худшей моделью оказалась LinearSVR, без подбора параметров дает вообще отрицательный результат по оценке r2. AutoML также выбрал модель градиентного бустинга как оптимальную.

16 Список использованных источников

- Конспекты лекций - https://github.com/ugapanyuk/ml_course_2021/wiki/COURSE_TMO
- Документация библиотеки skit-learn - https://scikit-learn.org/stable/user_guide.html
- Документация библиотеки streamlit - https://docs.streamlit.io/en/stable/
- Использованный набор данных для обучения - https://www.kaggle.com/harlfoxem/housesalesprediction?select=kc_house_data.csv
- Jupyter Lab - https://jupyterlab.readthedocs.io/en/stable/index.html